



Fakultät Wirtschaftswissenschaften

Professur für Wirtschaftsinformatik, insb.
Informationssysteme in Industrie und Handel

The Impact of AI Technology on Algorithmic Trading

Seminararbeit

Forschungsseminar

Eingereicht von:	Li, Wanjin
E-Mail:	wanjin.li@mailbox.tu-dresden.de
Matrikelnummer:	4904196
Studiengang:	Wirtschaftsinformatik
Referent/in:	Prof. Dr. Susanne Strahringer
Betreuer/in:	Dr. Raoul Hentschel
Bearbeitungszeit:	01.08.2024 – 12.11.2024

Abstract

Die kontinuierliche Entwicklung der KI-Technologien führt dazu, dass Forscherinnen und Forscher aus unterschiedlichen Fachgebieten zunehmend Interesse daran zeigen, diese Technologien in ihren jeweiligen Disziplinen anzuwenden. Damit verfolgen sie das Ziel, neue wissenschaftliche Erkenntnisse zu gewinnen oder die Produktivität zu steigern. Diese Studie verfolgt ebenfalls das Ziel, im Einklang mit den Fortschritten der KI-Technologie durch die Analyse der Anwendung von KI im Bereich des algorithmischen Handels bestehende Methoden und Praktiken der wissenschaftlichen Gemeinschaft aufzuzeigen und den Einfluss von KI auf den algorithmischen Handel zu untersuchen. In diesem Bereich erhoffen sich die Forschenden durch den Einsatz diverser KI-Technologien eine Steigerung der Leistungsfähigkeit algorithmischer Handelssysteme sowie eine Verbesserung der Rentabilität.

Die Auswirkungen aktueller Forschungsergebnisse zu verschiedenen KI-Technologien im algorithmischen Handel wurden durch eine systematische Literaturrecherche in drei Datenbanken untersucht, wobei die Methode der systematischen Literaturanalyse zum Einsatz kam. Die analysierte Literatur lässt erkennen, dass bestehende KI-Technologien in der wissenschaftlichen Forschung im Wesentlichen in drei Kategorien unterteilt werden können. Die drei wesentlichen Kategorien von KI-Technologien sind Machine Learning, Deep Learning und Reinforcement Learning. Traditionelle maschinelle Lernmethoden finden häufig Anwendung in der Prognose von Markttendenzen, beispielsweise in Form von Klassifikationsaufgaben mit Machine Learning Algorithmen wie Random Forest und Support Vector Machines. Die Fähigkeit von Deep Learning, hochdimensionale und abstrakte Informationen zu extrahieren, macht es zu einem geeigneten Merkmalsextraktor für Finanzzeitreihendaten. Die Forschungsrichtung des Reinforcement Learning hat das Interesse vieler Wissenschaftler geweckt, da hier durch die kontinuierliche Interaktion eines Agenten mit der Umgebung dynamische Investitionsstrategien entwickelt werden können. Dies stellt eine Möglichkeit dar, die Schwäche algorithmischer Handelssysteme, die auf Marktveränderungen nur begrenzt reagieren können, zu beheben.

Die vorliegende Studie präsentiert eine Wissenslandkarte, welche die Anwendung von KI-Technologien im algorithmischen Handel veranschaulicht. Zudem werden die sich daraus ergebenden Chancen und Herausforderungen analysiert. Die Ergebnisse dieser Arbeit können als Grundlage für vertiefte theoretische Untersuchungen sowie die Entwicklung von Systemen im algorithmischen Handel in der Zukunft dienen.

Inhaltsverzeichnis

Abbildungsverzeichnis	IV
Tabellenverzeichnis	V
Formelverzeichnis.....	VI
Abkürzungsverzeichnis	VII
1 Einleitung	1
1.1 Motivation	1
1.2 Forschungsbeitrag	2
1.3 Forschungsdesign.....	4
2 Theoretischer Hintergrund.....	5
2.1 Algorithmisches Handeln.....	5
2.2 Hochfrequenzhandel.....	7
2.3 KI-Technologien	7
2.3.1 Machine Learning	9
2.3.2 Deep Learning.....	10
2.3.3 Reinforcement Learning	12
3 Methodik.....	13
3.1 Aufbau der Suchstrategie	14
3.2 Eingrenzungsprozess	14
4 Ergebnisse.....	17
4.1 Eine automatisierte Exit- und Wiedereinstiegsstrategie.....	17
4.2 Machine Learning	18
4.2.1 Klassifikationsalgorithmen zur Markttrendprognose	19
4.2.2 Regressionsalgorithmen zur Markttrendprognose	20
4.2.3 Cluster-Algorithmen	20
4.3 Deep Learning.....	21
4.3.1 CNN	21
4.3.2 LSTM & BiLSTM	22
4.4 Deep Reinforcement Learning	22
4.4.1 Recurrent Reinforcement Learning.....	23
4.4.2 Hybride Methode	23
4.4.3 Directional Change Reinforcement Learning	25
4.4.4 Einbindung von Sentimentanalyse in RL	25
5 Diskussion	26
5.1 Methoden und Praktiken in der Literatur	26
5.2 Chancen und Herausforderungen durch AI.....	28
5.3 Reflexion und Ausblick.....	30
Literaturverzeichnis	33

Anhang A: Titel des Anhangs.....	VII
Anhang B: Titel des Anhangs	VIII

Abbildungsverzeichnis

Abbildung 1: Rahmenwerk für Literaturanalyse (Vom Brocke et al., 2009)	4
Abbildung 2: Verhältnis der KI-bezogenen Konzepte (Sahu et al., 2023, S. 10).....	8
Abbildung 3: Struktur der künstlichen neuronalen Netzwerke (Sahu et al., 2023, S. 13).....	11
Abbildung 4: Die Struktur von LSTM (Huang & Song, 2023, S. 1944).....	12
Abbildung 5: Reinforcement Learning Prozess (Shavandi & Khedmati, 2022, S. 5).....	13
Abbildung 6: Eingrenzungsprozess	17
Abbildung 7: Ein Prozessdiagramm der automatisierten Preissprungausstiegs- und Wiedereinstiegsstrategie (Koegelenberg & van Vuuren, 2024, S. 13).....	18
Abbildung 8: Handelssystem basierend auf RRL (Huang & Song, 2023, S. 1942).....	23
Abbildung 9: Die Struktur von DNN/LSTM/BiLSTM-RL (Huang & Song, 2023, S. 1943).....	24

Tabellenverzeichnis

Tabelle 1: Suchvorgänge in Datenbanken	16
Tabelle 2: Architektur vom Q-Netzwerk	26

Formelverzeichnis

Formel 1: Sharpe-Quotient	6
---------------------------------	---

Abkürzungsverzeichnis

Abk.	Abkürzung
ANN	Artificial Neural Networks
BiLSTM	Bi-directional Long Short-Term Memory
DCRL	Directional Change Reinforcement Learning
DFN	Deep Feedforward Network
DL	Deep Learning
DNN	Deep Neural Network
DRL	Deep Reinforcement Learning
DT	Decision Tree
HFT	High-Frequency Trading
KI	Künstliche Intelligenz
ML	Machine Learning
MLP	Multi Layer Perceptron
NB	Naive-Bayes
RF	Random Forest
RL	Reinforcement Learning
RNN	Recurrent Neural Networks
RRL	Recurrent Reinforcement Learning
RW-Suche	Rückwärtssuche
SVM	Support Vector Machine
SVR	Support Vector Regression
VaR	Value at Risk

1 Einleitung

1.1 Motivation

In den vergangenen Jahrzehnten hat sich der algorithmische Handel zunehmend zu einem maßgeblichen Trend im Finanzhandel entwickelt (Huang & Song, 2023). Dies ist darauf zurückzuführen, dass in erheblichem Umfang Zeit und Ressourcen in die Gestaltung und Implementierung algorithmischer Handelssysteme investiert wurden. Dadurch wird es Investoren ermöglicht, sich auf den Finanzmärkten einen wettbewerbsfähigen Informationsvorsprung zu verschaffen (Koegelenberg & van Vuuren, 2024). Finanzmärkte sind jedoch von Natur aus komplex, unsicher und dynamisch, was den Handel erschwert (Shavandi & Khedmati, 2022). Eine Vielzahl von Faktoren, darunter ökonomische Indikatoren, die Stimmung der Investoren sowie das Verhalten anderer Marktteilnehmer, übt einen Einfluss auf den Finanzhandel aus (Huang, Zhou, et al., 2024b). Der kontinuierlichen Integration neuer Technologien und Algorithmen in Handelsstrategien liegt das Bestreben zugrunde, höhere Handelsgewinne zu erzielen. Im Vergleich zu traditionellen Handelsmethoden bietet der algorithmische Handel eine Reihe von Vorteilen hinsichtlich Geschwindigkeit, Genauigkeit, Rationalität, Verarbeitungskapazität und Wachsamkeit (Shavandi & Khedmati, 2022).

Mit dem Aufstieg generativer künstlicher intelligenter (KI) Systeme, wie beispielsweise *Chat-GPT*, hat sich das Interesse von Forschern aus unterschiedlichen Fachgebieten an den Anwendungen und Auswirkungen von KI in ihren jeweiligen Bereichen signifikant verstärkt. Die Einsatzmöglichkeiten von KI im Alltag nehmen zu und führen dazu, dass Menschen von komplexen Aufgaben befreit werden. Aufgrund der hohen Komplexität des Finanzsektors stellt dieser seit jeher ein bevorzugtes Anwendungsgebiet für die Forschung im Bereich KI dar. Eine Vielzahl von Finanzinstitutionen, darunter Banken, Fondsverwaltungsgesellschaften und Vermögensverwalter, misst KI-Technologien wie *Machine Learning* (ML), *Deep Learning* (DL) und *Reinforcement Learning* (RL) eine hohe Priorität bei, um damit ihre Investitionsstrategien zu optimieren (Sahu et al., 2023).

Der algorithmische Handel hat sich von einer anfänglichen Abhängigkeit von statistischen Modellen und ökonometrischen Modellen (Huang & Song, 2023; Jain et al., 2021) sowie Hochfrequenzhandel (Vo & Yost-Bremm, 2020), mit dem das Ziel der Renditemaximierung bei Einzelanlagen verfolgt wurde, zu einer Phase entwickelt, in der investitionsunterstützende Werkzeuge auf der Basis von *Deep Reinforcement Learning* (DRL) zum Einsatz kommen (Shavandi & Khedmati, 2022). Die Entwicklung von KI-Technologien stellt dabei einen unabdingbaren Impulsgeber dar. In modernen algorithmischen Handelsstrategien finden KI-Technologien, darunter ML und DL, mittlerweile breite Anwendung zur Datenverarbeitung und Prognose, um Handelssignale zu identifizieren (Huang & Song, 2023). Dies ist darauf zurückzuführen, dass maschinelle Lernverfahren in der Lage sind, die Defizite traditioneller Methoden bei der Erkennung verborgener Zusammenhänge und Muster zu überwinden (Gurung et al., 2024).

Obwohl bereits viele Wissenschaftler und Forscher durch praktische Fallstudien eine vertiefte Untersuchung der Anwendung von KI-Technologien im algorithmischen Handel vorgenommen

haben, lassen sich unterschiedliche Herangehensweisen beobachten. Einige Forscher neigen dazu, durch Vergleichsexperimente die Leistungsunterschiede verschiedener KI-Technologien in Bezug auf die Steigerung von Anlagerenditen und die Senkung von Handelsrisiken zu analysieren. So wurde beispielsweise von Huang & Song (2023) die Performance eines hybriden Ansatzes, der auf *Recurrent Reinforcement Learning* (RRL) und einem *Bi-directional Long Short-Term Memory* (BiLSTM)-Modell, im Vergleich zu Einzelmethode am US-Aktienmarkt analysiert. Einige Forscher widmen sich der Entwicklung spezieller algorithmischer Handelsmodelle für bestimmte Finanzmärkte. So haben Alaminos et al. (2024) etwa eine Handelsstrategie für Kryptowährungen entwickelt, die genetische Algorithmen mit KI-Technologien kombiniert.

Obwohl die Generierung hoher Anlagerenditen durch den Einsatz fortschrittlicher KI-Technologien eine signifikante Relevanz in der Forschung zum algorithmischen Handel einnimmt, sind die durch technologische Transformationen induzierten Implikationen ebenfalls Gegenstand umfangreicher Forschungsaktivitäten. Der breiten Verfügbarkeit großflächig verfügbarer, qualitativ hochwertiger Finanzdaten sowie den bahnbrechenden Fortschritten im Bereich der KI ist es zu verdanken, dass neue, komplexere algorithmische Handelsstrategien entwickelt werden konnten (Gurung et al., 2024). Infolge der kontinuierlichen Entwicklung von KI-Technologien in den vergangenen Jahrzehnten umfasst der algorithmische Handel auf nahezu alle Finanzmärkte, darunter Aktienmärkte, Terminmärkte, Kryptowährungsbörsen und zahlreiche weitere.

Derzeit besteht jedoch in der akademischen Welt ein Mangel an einer zusammenfassenden Analyse der durch KI bedingten Auswirkungen im algorithmischen Handel aus technischer Sicht. Dies ist darauf zurückzuführen, dass der algorithmische Handel eine komplexe interdisziplinäre Disziplin ist, die nicht nur die Wirtschaftswissenschaften und Finanzwissenschaften, sondern auch die Informatik umfasst. Die Komplexität des algorithmischen Handels erschwert zudem den Zugang für Forscherinnen und Forscher aus unterschiedlichen akademischen Hintergründen zu diesem Forschungsfeld. Daher verfolgt diese Studie das Ziel, durch eine systematische Literaturanalyse die neuesten Forschungsergebnisse zu Methoden und Praktiken im algorithmischen Handel zu untersuchen. Auf Basis der gewonnenen Erkenntnisse soll in einem nächsten Schritt untersucht werden, welche Chancen und Herausforderungen die Entwicklung von KI-Technologien für die algorithmische Handelsbranche mit sich bringt.

1.2 Forschungsbeitrag

Die hohen Anforderungen an Mathematik und Computeralgorithmen, welche die interdisziplinäre Disziplin des algorithmischen Handels stellt, erweisen sich für Forscher, an diesem Forschungsgebiet Interessierte sowie andere Beteiligte aus verschiedenen Branchen als beträchtliche Hürde. So erweist sich beispielsweise die Rezeption von Arbeiten über den algorithmischen Handel und die entsprechenden KI-Technologien für Finanzwissenschaftler, die mit KI-Technologien nicht vertraut sind, als herausfordernd. Gleichwohl ist es für Entwickler und IT-Fachleute, denen die Regeln der Finanzmärkte und Anlagestrategien fremd sind, ebenfalls schwierig, leistungsfähige Werkzeuge für den algorithmischen Handel zu entwickeln. Auch der akademische Diskurs zwischen Forschern unterschiedlicher Disziplinen ist häufig durch eine ineffiziente wechselseitige Kommunikation gekennzeichnet.

Die Zielsetzung dieser systematischen Literaturrecherche besteht in der Analyse der jüngsten Forschungsergebnisse und bewährter Vorgehensweisen im Bereich des algorithmischen Handels. Auf diese Weise sollen anderen Forschern häufig verwendete Lösungen und das für deren Umsetzung notwendige Grundlagenwissen bereitgestellt werden. Des Weiteren zielt die Studie darauf ab, die mit der Einführung von KI verbundenen Chancen und Herausforderungen zu erörtern. Dazu werden die Theorien und praktischen Ansätze anderer Forscher zusammengefasst und diskutiert. Die Relevanz dieser Studie variiert in Abhängigkeit von der Perspektive der Marktteilnehmer im Finanzhandel sowie weiterer Interessengruppen.

Die vorliegende Studie ist vor dem Hintergrund einer zunehmend großflächigen Anwendung von KI-Produkten darauf ausgerichtet, eine fundierte Wissensbasis für Forscherinnen und Forscher aus unterschiedlichen Fachbereichen zu schaffen. Gleichzeitig zielt sie darauf ab, eine Brücke zwischen den verschiedenen Disziplinen zu schlagen und eine Grundlage für einen interdisziplinären Austausch zu etablieren. Die Ergebnisse der Studie ermöglichen es interessierten Personen und anderen Interessengruppen, sich grundlegendes Wissen über die in algorithmischen Handelsstrategien verwendeten KI-Technologien anzueignen. Für Experten auf dem Gebiet der KI besteht die Möglichkeit, ihre Fachkenntnisse auf ein vielversprechendes Anwendungsfeld auszudehnen.

Die vorliegende Studie verfolgt das Ziel, auf Basis der genannten Forschungsziele und bestehenden Forschungslücken eine Antwort auf zwei miteinander verbundene Forschungsfragen zu finden. Dies erfolgt durch die Zusammenfassung und Analyse der in der Praxis weit verbreiteten KI-Technologien im algorithmischen Handel in Kombination mit den Eigenschaften der Finanzmärkte. Die erste Forschungsfrage zielt auf eine Analyse der KI-Technologien im algorithmischen Handel auf unterschiedlichen Finanzmärkten ab. Die Beantwortung dieser Frage zielt darauf ab, den Interessengruppen eine Orientierungshilfe bei der Auswahl geeigneter algorithmischer Handelsstrategien für verschiedene Finanzmärkte zur Verfügung zu stellen. Die Beantwortung der ersten Forschungsfrage trägt zugleich zur Beantwortung der zweiten Forschungsfrage bei. Um die Chancen und Herausforderungen, die durch die Einführung von KI-Technologien entstehen, zu identifizieren, ist eine Analyse der Eigenschaften der verschiedenen KI-Technologien unabdingbar. Die individuellen Anforderungen der verschiedenen KI-Technologien an das Wissen der Interessengruppen sowie die starken Variationen hinsichtlich der Hardware-Anforderungen zur Implementierung der Technologien erfordern eine individuelle Betrachtung der Chancen und Herausforderungen der einzelnen KI-Technologien. Die vorliegende Studie verfolgt das Ziel, durch eine systematische Literaturanalyse sowohl die Chancen als auch die Herausforderungen der KI zu untersuchen. Auf diese Weise soll den Praktikern eine Hilfestellung geboten werden, um das optimale Gleichgewicht zwischen Leistung und Kosten zu finden.

Forschungsfrage 1: *Welche Methoden und Praktiken des algorithmischen Handels existieren in der Literatur?*

Forschungsfrage 2: *Welche Herausforderungen und Chancen bietet die Integration von KI in bestehende algorithmische Handelssysteme?*

1.3 Forschungsdesign

Das dieser Arbeit zugrunde liegende Forschungsdesign orientiert sich an den von Vom Brocke et al. (2009) formulierten Leitlinien für die Konzeption eines Untersuchungsplans für eine systematische Literaturrecherche. Die durchzuführenden Schritte sind in einem fünfstufigen Rahmen zusammengefasst, wie in Abbildung 1 dargestellt.




Abbildung 1: Rahmenwerk für Literaturanalyse (Vom Brocke et al., 2009)

Der erste Schritt der systematischen Literaturanalyse besteht in der Festlegung des angemessenen Umfangs der Recherche. Um das zu untersuchende Thema sinnvoll einzugrenzen, sind zunächst spezifische Fragestellungen zu formulieren. In diesem Kontext werden in Abschnitt 1.2 zwei Forschungsfragen definiert (Vom Brocke et al., 2009).

Im zweiten Schritt erfolgt die Konzeptualisierung des Themenbereichs, wobei zunächst die zugrunde liegenden theoretischen Grundlagen definiert und anschließend miteinander in Zusammenhang gebracht werden. Das Ziel dieser Untersuchung besteht darin, einen strukturierten Überblick über den Einsatz von KI-Technologien im Bereich des algorithmischen Handelns zu gewinnen. Ein detaillierter Überblick über die relevanten Begriffe und Konzepte wird in Abschnitt 2 präsentiert (Vom Brocke et al., 2009).

Im dritten Schritt erfolgt die Literatursuche, wobei mit der konkreten Arbeit mit potenziell relevanter Literatur begonnen wird. Der Suchprozess bildet die Grundlage für mehrere Suchdurchläufe und umfasst die Datenbank-, Schlagwort-, Vorwärts- und Rückwärtssuche. Die Vorgehensweise ist dabei detailliert zu formulieren und zu dokumentieren. Im Anschluss erfolgt eine Beschränkung der ermittelten Literatur auf Artikel, die für die Untersuchung des Themas relevant sind. Der Selektionsprozess umfasst mehrere Auswahlsschritte, die mit Titel- und Abstractscreenings beginnen und mit Volltextüberprüfungen enden. Das Ergebnis dieses Prozesses ist eine

Übersicht der relevanten Literatur. Die genannten Schritte bilden die Methodik der vorliegenden Arbeit, welche in Abschnitt 3 näher erläutert wird (Vom Brocke et al., 2009).

Im Anschluss an die Literaturrecherche erfolgt im vierten Schritt eine detaillierte Analyse und Zusammenfassung der ausgewählten Quellen. Im Anschluss werden die gewonnenen Erkenntnisse in einen zum Bezugsrahmen des Themas passenden Zusammenhang gestellt, wobei stets eine Bezugnahme auf die zentralen Forschungsfragen erfolgt. Die in dieser Arbeit präsentierten Untersuchungsergebnisse sind ausdrücklich auf die formulierten Forschungsfragen bezogen (Vom Brocke et al., 2009).

Im abschließenden, fünften Schritt der systematischen Literaturrecherche erfolgt die Formulierung einer Forschungsagenda, welche zukünftige Forschungsperspektiven aufzeigt und als Grundlage für die Erweiterung der Analyse dient (Vom Brocke et al., 2009).

2 Theoretischer Hintergrund

In diesem Abschnitt erfolgt zunächst eine Erläuterung und Abgrenzung der in dieser Studie verwendeten gängigen Konzepte, um Lesern aus unterschiedlichen Forschungsbereichen ein grundlegendes Verständnis der in Zusammenhang mit dem algorithmischen Handel stehenden Fachtermini zu ermöglichen. Des Weiteren erfolgt eine Definition der spezifischen Bedeutungen dieser Konzepte, wie sie in dieser Studie verwendet werden, um Missverständnissen vorzubeugen. In Bezug auf die fachliche Zugehörigkeit erfolgt eine Unterteilung der Konzepte in zwei Kategorien: Im Folgenden werden die Konzepte im Kontext des Handelns sowie die Konzepte im Kontext von KI-Technologien erläutert.

2.1 Algorithmisches Handeln

Innerhalb der quantitativen Finanzwissenschaften existieren diverse ähnliche Konzepte, zu denen unter anderem der quantitative Handel, der algorithmische Handel, der Hochfrequenzhandel sowie der automatisierte Handel. Um eine Verwechslung der Begriffe zu vermeiden, werden diese im Folgenden ausführlich definiert. Obschon einige Forscherinnen und Forscher diese Konzepte streng voneinander abgrenzen, stellen sie in der Praxis unterschiedliche Anwendungen von KI im Investitionsbereich dar. Der quantitative Handel bedient sich Computeralgorithmen und Programmen, welche auf einfachen oder komplexen mathematischen Modellen basieren, um Handelsmöglichkeiten zu identifizieren und von diesen zu profitieren. Algorithmischer Handel bezeichnet die Ausführung von Aufträgen basierend auf vorgegebenen Kriterien wie Zeit, Preis und Volumen mit vorprogrammierten Handelsanweisungen. Der Hochfrequenzhandel, in der Literatur auch als HFT (*High-Frequency Trading*) bezeichnet, stellt eine Form des Handels dar, bei der hochentwickelte Computeralgorithmen zum Einsatz kommen, um eine große Anzahl von Aufträgen in sehr kurzer Zeit, d. h. innerhalb von Sekundenbruchteilen, auszuführen. Ein automatisiertes Handelssystem, eine Form des algorithmischen Handels, nutzt Computersoftware, um Kauf- und Verkaufsaufträge zu erteilen und automatisch an eine Marktbörse oder ein Handelszentrum zu übermitteln (Sahu et al., 2023).

Algorithmischer Handel bezeichnet eine Handelsstrategie, bei der computergestützte Algorithmen eingesetzt werden, um eine vordefinierte Handelsstrategie zu automatisieren (Tabaro et al., 2024). Eine Handelsstrategie ist in der Regel durch spezifische Indikatoren oder Signale gekennzeichnet, die aus Marktdaten abgeleitet werden und dem Händler als Entscheidungshilfe dienen, um den optimalen Zeitpunkt für den Kauf und Verkauf bestimmter Vermögenswerte zu bestimmen (Tabaro et al., 2024). Die Möglichkeit, mittels algorithmischen Handels schneller auf Marktbewegungen reagieren zu können, eröffnet die Chance, potenziell höhere Gewinne zu erzielen.

Obschon sich die exakten Definitionen dieser Konzepte einer allgemeingültigen Festlegung entziehen, ist ihre gegenseitige Beziehung zu berücksichtigen. Diesbezüglich sei auf die Möglichkeit verwiesen, dass auch die Forschung und Praxis des HFT durch KI-Technologien umgesetzt werden kann (Vo & Yost-Bremm, 2020). Die Ergebnisse der Literaturrecherche legen nahe, dass in den meisten Studien der vergangenen fünf Jahre keine klare Unterscheidung zwischen algorithmischem Handel und Hochfrequenzhandel getroffen wurde. In der vorliegenden Studie, welche den Einfluss von KI auf den algorithmischen Handel untersucht, wird die Definition von Chang & Chou (2022) zugrunde gelegt. Dies impliziert, dass Hochfrequenzhandel in dieser Studie als eine Unterkategorie des algorithmischen Handels betrachtet wird.

In der Literatur findet sich die Auffassung, dass der algorithmische Handel auch als *Black-Box*-Handel oder automatisierter Handel bezeichnet werden kann. Dabei werden Investitionsentscheidungen durch auf Computern implementierte KI-Modelle oder vordefinierte quantitative Handelsregeln unterstützt (Gurung et al., 2024). Dies impliziert, dass algorithmischer Handel sowohl auf der Grundlage vordefinierter Regeln als auch durch maschinelles Lernen umgesetzt werden kann (Huang, Zhou, et al., 2024a; Shavandi & Khedmati, 2022). In seiner traditionellen Ausgestaltung basiert der algorithmische Handel auf den Erfahrungen menschlicher Experten oder auf festgelegten Regeln, wie etwa Trendfolge oder *Mean-Reversion*-Strategien (Huang & Song, 2023). In modernen algorithmischen Handelssystemen, die auf ML basieren, erfolgt zunächst eine Trainingsphase des Computers auf Basis historischer Daten, woraufhin er ohne menschliches Eingreifen handelt (Shavandi & Khedmati, 2022). Der Handelsprozess kann als ein Entscheidungsprozess definiert werden, dessen Ziel die Gewinnmaximierung und gleichzeitig das Risikominimierung ist. Im Gegensatz zu menschlichen Entscheidern unterliegt der Entscheidungsprozess der KI nicht den negativen Auswirkungen von Emotionen, wodurch die Investitionsentscheidung des Computers frei von diesen ist (Shavandi & Khedmati, 2022).

Der Sharpe-Quotient stellt ein Instrument zur Evaluierung der Performance einer einzelnen Transaktion dar, welches die Effektivität einer Handelsstrategie quantifizieren kann (Sokolovsky & Arnaboldi, 2023). Die Berechnung des Sharpe-Quotienten erfolgt gemäß der folgenden Formel 1:

Formel 1: Sharpe-Quotient

$$S = \frac{R_p - R_f}{\sigma_p}$$

wobei R_p und R_f jeweils die Rendite des Portfolios und die risikofreie Rendite in der aktuellen Transaktion darstellen, während der Nenner die Standardabweichung der Portfoliorendite σ_p bezeichnet. Eine geringere Standardabweichung impliziert ein geringeres Risiko und eine höhere Sharpe Ratio, während das Gegenteil auf ein höheres Risiko hinweist (Takara et al., 2024). Die Ergebnisse der Literaturrecherche legen nahe, dass die Mehrheit der Forscher die Sharpe Ratio als maßgeblichen Index zur Bewertung der Performance von KI-gestützten algorithmischen Handelssystemen betrachtet. Darüber hinaus findet die Sharpe Ratio auch als Verlust- und Belohnungsfunktion in der Forschung zum algorithmischen Handel mit DL und RL Anwendung, um die Leistung von Computeralgorithmen zu optimieren.

2.2 Hochfrequenzhandel

Die Anfänge des Hochfrequenzhandels lassen sich bis ins Jahr 1998 zurückverfolgen (Goldstein et al., 2014). Wie im ersten Kapitel dieser Studie dargelegt, wird der Hochfrequenzhandel als eine spezielle Form des algorithmischen Handels betrachtet. Algorithmischer Handel findet typischerweise auf entwickelten Finanzmärkten Anwendung, wie beispielsweise dem amerikanischen Aktienmarkt oder anderen Währungsmärkten in entwickelten Volkswirtschaften (Vo & Yost-Bremm, 2020).

Hochfrequenzhandel bezeichnet den Einsatz computergestützter Handelsalgorithmen, welche darauf abzielen, Vermögenswerte in kurzen Zeitintervallen zu erwerben und zu veräußern. Dabei wird eine Haltedauer auf Niveau von Minuten, Sekunden oder sogar Millisekunden angestrebt, um minimale Gewinnmargen bei jedem Handel zu erzielen (Vo & Yost-Bremm, 2020). Idealierte Strategien des Hochfrequenzhandels basieren folglich auf dynamischen Handelsstrategien, die eine automatische Anpassung an die Markttrends ermöglichen (Chakole et al., 2021). In der akademischen Forschung hat sich die Entwicklung und Optimierung von Modellen etabliert, die auf DRL basierende Algorithmen zur Gestaltung dynamischer Handelsstrategien nutzen. Als Beispiel für diese Argumentation kann die Aussage von Tabaro et al. (2024) angeführt werden, wonach RL und algorithmischer Handel eine perfekte Kombination darstellen.

2.3 KI-Technologien

Um den Lesern ein grundlegendes Verständnis dieser Studie zu ermöglichen, ist es erforderlich, die verschiedenen Konzepte im Kontext von KI klar voneinander abzugrenzen. Der Begriff der KI umfasst alle Techniken, die es Computern ermöglichen, menschliches Verhalten nachzuahmen und Entscheidungen zu treffen, um komplexe Aufgaben unabhängig oder mit minimalem menschlichem Eingreifen zu lösen (Russell et al., 2003). Die nachfolgende Abbildung 2 veranschaulicht das Verhältnis der KI-bezogenen Konzepte zueinander. Dabei umfasst KI ML, während DL und RL Unterkategorien des maschinellen Lernens sind.




Abbildung 2: Verhältnis der KI-bezogenen Konzepte (Sahu et al., 2023, S. 10)

ML ist ein breit gefasstes Konzept, und viele Forscher setzen in ihren Arbeiten maschinelles Lernen mit KI gleich oder verwenden den Oberbegriff maschinelles Lernen, um spezifischere Techniken wie DL und RL zu bezeichnen. In der vorliegenden Studie wird eine klare Definition zugrunde gelegt, nach der ML als eigenständiges Konzept neben anderen KI-Technologien betrachtet wird. Wenn der Begriff maschinelles Lernen als Oberbegriff verwendet wird, um andere KI-Technologien zu umfassen, wird in dieser Studie stattdessen der Begriff KI verwendet.

Maschinelle Lernalgorithmen erweisen sich im algorithmischen Handel als außerordentlich effektives Instrument, da sie die simultane Analyse einer Vielzahl von Indikatoren auf den Finanzmärkten ermöglichen (Barucci et al., 2021). Der Analyseprozess erfolgt durch die Extraktion von Datenmustern auf den Finanzmärkten mittels maschineller Lernalgorithmen (Sahu et al., 2023). In Abhängigkeit von der Art der zu lösenden Probleme sowie den verfügbaren Daten lässt sich maschinelles Lernen in zwei Kategorien unterteilen: überwachtes und unüberwachtes Lernen (Janniesch et al., 2021). Im algorithmischen Handel kann überwachtes Lernen zur Prognose der zukünftigen Tendenzentwicklung eines Vermögenswerts auf einem Markt eingesetzt werden. Die Theorie der effizienten Märkte besagt jedoch, dass die Preise von Aktien alle aktuell verfügbaren Informationen widerspiegeln sollten. Somit sind Preisänderungen, die nicht auf neuen Informationen basieren, grundsätzlich unvorhersehbar (Sahu et al., 2023).

In Bereichen, in denen große und hochdimensionale Datenmengen verarbeitet werden müssen, erweist sich DL als besonders nützlich. Dies trifft insbesondere auf die Verarbeitung von Text-, Bild-, Video-, Sprach- und Audiodaten zu. In diesen Anwendungsbereichen zeigen tiefe neuronale Netze eine höhere Leistungsfähigkeit als flache maschinelle Lernalgorithmen (Lecun et al., 2015). DL verwendet typischerweise tiefe neuronale Netzwerke, die mehr als eine verborgene Schicht enthalten. Die künstlichen Neuronen sind dabei in einer netzartigen Struktur organisiert, wie sie für tiefgehende neuronale Netzwerke charakteristisch ist.

Im Vergleich zu anderen Ansätzen des maschinellen Lernens legt RL einen stärkeren Fokus auf zielgerichtetes Lernen durch Interaktion. Sequenzielle Interaktion eines Agenten mit seiner

Umgebung stellt ein zentrales Element dar. In der initialen Phase beobachtet der Agent den Zustand der Umgebung, woraufhin er eine auf seiner Policy basierende Aktion ausführt. Als Resultat dieser Aktion erhält er eine Belohnung (Huang, Wan, et al., 2024).

DRL kombiniert die Wahrnehmungsfähigkeit des DL mit der Entscheidungsfindungskompetenz des RL, um die Abbildung zwischen den Zuständen der Finanzmärkte und den Handelsentscheidungen durch die Interaktion mit der Umgebung zu erlernen (Huang, Wan, et al., 2024)

2.3.1 Machine Learning

Die von ML ermöglichte Revolutionierung des algorithmischen Handels basiert auf der Fähigkeit von Systemen, aus Daten zu lernen und sich an sich verändernde Marktbedingungen anzupassen. Zu den auf ML basierenden Ansätzen zählen diverse Techniken, darunter das Überwachte Lernen, das Unüberwachte Lernen sowie RL. Die Algorithmen analysieren historische Daten, identifizieren Muster und treffen Vorhersagen über zukünftige Marktbewegungen. Der wesentliche Vorteil des maschinellen Lernens besteht in der Fähigkeit, nichtlineare Zusammenhänge aufzudecken und sich an die sich entwickelnde Marktdynamik anzupassen. (Wilhelmina Afua Addy et al., 2024).

Im Rahmen der quantitativen Finanzwissenschaft finden maschinelle Lernmethoden Anwendung, um präzisere Prognosen zu generieren sowie die Performance von Finanzmodellen zu optimieren. Allerdings ist zu berücksichtigen, dass nicht alle maschinellen Lernmethoden für alle Problemstellungen geeignet sind. Die Auswahl des Modells sollte auf den spezifischen Charakteristika des zu lösenden Problems und den verfügbaren Daten basieren. Daher ist eine Zusammenarbeit von Experten aus dem Bereich des maschinellen Lernens und der Finanzwirtschaft erforderlich, um optimale Ergebnisse zu erzielen (Sahu et al., 2023).

In finanziellen Anwendungen finden häufig Klassifikationsalgorithmen Anwendung, welche eine bestimmte Aktie in Kategorien wie „STRONG BUY“ oder „STRONG SELL“ sowie „BUY“, „SELL“ und „HOLD“ einordnen (Sahu et al., 2023). Ein weit verbreiteter Klassifikationsalgorithmus ist der Naive-Bayes-Algorithmus. Der Naive-Bayes-Algorithmus ist ein Klassifikationsalgorithmus, der eine Entscheidungsstrategie prognostiziert, nachdem er den Satz von Prädiktoren beobachtet hat. Allerdings erschwert die ungleichmäßige Verteilung der Klassenlabels in den Datensätzen die Klassifikationsaufgaben (Sahu et al., 2023), weshalb die Lösung dieses Problems und die Effizienzsteigerung von ML-Modellen dringend erforderlich sind.

Unter den einfachen und gleichzeitig höchst effektiven Techniken ist die Methode der *Support Vector Machines* (SVM) zu nennen (Janardhanan & Sabika, 2015). SVMs werden eingesetzt, um die Hyperebene zu identifizieren, die eine binäre Stichprobe am besten trennt. Bei einer Vielzahl von Punkten auf einer zweidimensionalen Ebene wird die SVM diejenige Gerade finden, welche die beiden unterschiedlichen Klassifikationen voneinander am besten trennt. Die Anwendung dieser Technik ist auch auf höherdimensionale Daten möglich. Aufgrund ihrer Einfachheit ist die Klassifikation nachvollziehbar und intuitiv verständlich (Sokolovsky & Arnaboldi, 2023).

Zu den weiteren, in der Praxis etablierten Klassifikationsmethoden zählen *Decision Tree* (DT) sowie *Random Forest* (RF). Der Grund für die hohe Akzeptanz dieser baumbasierten

Klassifikationsmethoden liegt in ihrer guten Interpretierbarkeit. Die Funktionsweise von RF basiert auf der Konstruktion einer Vielzahl von Entscheidungsbäumen während der Trainingsphase, wobei das Ergebnis der Klassifikation aus den individuellen Bäumen abgeleitet wird (Sokolovsky & Arnaboldi, 2023).

Im Gegensatz zu den sogenannten Klassifikationsproblemen, bei denen die Zielvariablen diskrete Klassenlabels aufweisen, handelt es sich bei Regressionsproblemen um kontinuierliche Zielvariablen. Ein Beispiel für ein Regressionsproblem ist die Prognose des zukünftigen Trends eines Vermögenswerts (Sahu et al., 2023). Die Komplexität der Finanzmärkte bedingt jedoch, dass die Verwendung einfacher linearer Regressionsmodelle zur Lösung von Regressionsproblemen mit mehreren unabhängigen Variablen nicht ausreichend ist.

Die *Ridge Regression* stellt ein Modell zur Schätzung der Koeffizienten von multiplen Regressionsmodellen in Fällen, in denen die unabhängigen Variablen stark korreliert sind. *Ridge Regression* ist besonders nützlich, um das Problem der Multikollinearität in der linearen Regression zu mindern, was vor allem bei Algorithmen mit einer großen Anzahl von Parametern auftritt (Gurung et al., 2024).

2.3.2 Deep Learning

DL-Technologien stellen eine Form des maschinellen Lernens dar, welche auf der Verwendung künstlicher neuronaler Netzwerke (*Artificial Neural Networks*, ANNs) basieren. Ein ANN umfasst eine Eingabeschicht, eine oder mehrere verborgenen Schichten sowie eine Ausgabeschicht, wie in der nachfolgenden Abbildung 3 dargestellt. Wenn ein ANN mehr als eine verborgene Schicht besitzt, wird es als *Deep Neural Network* (DNN) bezeichnet, auch bekannt als *Deep Feedforward Network* (DFN) oder *Multi Layer Perceptron* (MLP).

Jedem künstlichen Neuron ist ein Gewicht zugewiesen, zudem verfügt es über einen Schwellenwert. Darüber hinaus ist es mit anderen Neuronen verbunden. Die Weitergabe von Daten an die nachfolgende Schicht erfolgt durch die Knoten, sobald der Ausgangswert den Schwellenwert überschreitet. Um das menschliche Gehirn zu simulieren, sind die Schichten eines künstlichen neuronalen Netzwerks miteinander verbunden (Sahu et al., 2023). Die Eingabemerkmale eines ANNs setzen sich aus vorverarbeiteten Daten über den Finanzmarkt, zusammen während die Ausgaben die gewünschten Vorhersageindikatoren darstellen. DL kombiniert Merkmale durch mehrschichtige Netzwerkstrukturen und nichtlineare Transformationen, wodurch sich starke Wahrnehmungs- und Darstellungskapazitäten ergeben (Huang & Song, 2023).




Abbildung 3: Struktur der künstlichen neuronalen Netzwerke (Sahu et al., 2023, S. 13)

Recurrent Neural Networks (RNNs) haben sich in verschiedenen Anwendungsbereichen, insbesondere bei der Vorhersage von Zeitreihen, aufgrund ihrer starken Vorhersagefähigkeiten großen Erfolg erzielt (Alaminos et al., 2024). Als neuronale Netzwerke zur Verarbeitung von sequenziellen Daten zeichnet sich das RNN vor allem durch seine rekursive Struktur aus, die es ihm ermöglicht, frühere Eingabeinformationen zu speichern (Huang & Song, 2023). In Aufgaben wie Zeitreihenanalyse und natürlicher Sprachverarbeitung kann RNN die zeitliche oder sequenzielle Abhängigkeit nutzen. Allerdings weisen traditionelle RNNs das Problem des verschwindenden Gradienten auf, was ihre Fähigkeit einschränkt, lange Sequenzen zu erlernen.

Das LSTM-Modell stellt eine Weiterentwicklung des RNN-Modells dar, welche die Problematik des Verschwindens des Gradienten bei RNNs zu lösen vermag. Das LSTM-Modell führt Gedächtniszellen sowie einen *Gate*-Mechanismus, welcher aus einem Eingangstor, einem Vergessenstor und einem Ausgangstor besteht. Dieser ermöglicht, langfristige Abhängigkeiten in langen Sequenzen effektiv zu erfassen. Daher weist LSTM bei Aufgaben, die eine Verarbeitung von Langzeitabhängigkeiten erfordern, eine exzellente Leistungsfähigkeit auf. Des Weiteren ist LSTM in der Lage, Eingabesequenzen variabler Länge zu verarbeiten, wobei hier der interne Zustand, also das Gedächtnis, eine entscheidende Rolle spielt (Huang & Song, 2023). Die nachfolgende Abbildung zeigt die Struktur einer LSTM-Einheit. Eine solche Einheit besteht aus einer Zelle c_t , einem Eingangstor i_t , einem Ausgangstor o_t sowie einem Vergessenstor f_t . Die Zelle speichert Werte über beliebige Zeitintervalle hinweg, während die drei Tore den Informationsfluss in und aus der Zelle regulieren (Huang & Song, 2023).

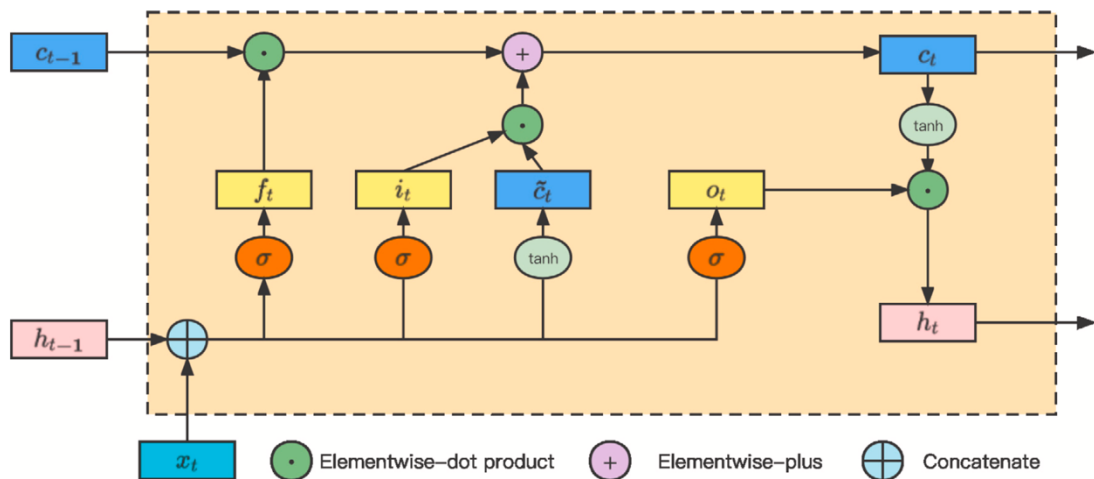


Abbildung 4: Die Struktur von LSTM (Huang & Song, 2023, S. 1944)

Unter der Voraussetzung, dass die Eingabefeatures eines Modells, wie etwa Zeitreihendaten, eine identische Länge aufweisen, besteht die Möglichkeit, Merkmale aus mehreren Perspektiven zu extrahieren. Dies bedeutet, dass die Ausgabe eines Moments nicht nur mit den Informationen vergangener Momente, sondern auch mit den Informationen nachfolgender Momente verknüpft ist. Daher erscheint die Hinzufügung einer zusätzlichen neuronalen Netzwerkschicht sinnvoll, um Informationen rückwärts zu übermitteln und so die Modellleistung zu verbessern. Die Implementierung eines LSTM, welches Informationen in beide Richtungen übermitteln, wird als bidirektionales LSTM bezeichnet. Ein BiLSTM stellt eine Erweiterung des LSTM dar, indem es zwei LSTM-Schichten miteinander kombiniert, die dasselbe Input-Signal verwenden, jedoch Informationen in unterschiedliche Richtungen weiterleiten (H.-H. Liu et al., 2023).

2.3.3 Reinforcement Learning

In Anbetracht der Natur des Trainingsprozesses erweist es sich als schwierig, ML und DL an dynamische Handelsstrategien anzupassen. Im Gegensatz zu dynamischen Handelsstrategien bleiben statische Handelsstrategien über den gesamten Handelsprozess hinweg unverändert. In Phasen zunehmender Unsicherheit auf den Finanzmärkten sind statische Handelsstrategien jedoch mit erheblichen Risiken verbunden. Daher ist eine Handelsstrategie, die in der Lage ist, sich selbstständig und entsprechend der sich ändernden Marktbedingungen zu optimieren, unerlässlich. Im Gegensatz zu den zuvor genannten Methoden des ML und DL ermöglicht RL durch die Interaktion eines Agenten mit seiner Umgebung und die Verwendung eines Belohnungsmechanismus eine Selbstoptimierung der Handelsstrategie mit dem Ziel, die optimale dynamische Handelsstrategie zu finden (Chakole et al., 2021; Huang & Song, 2023).

Wie in der untenstehenden Abbildung 5 dargestellt, umfasst ein RL-Modell mit einem einzelnen Agenten zwei Hauptkomponenten: den Agenten und die Umgebung. Die wiederholte Interaktion zwischen dem Agenten und der Umgebung resultiert in einer Sequenz von Zuständen, Aktionen und Belohnungen. Innerhalb dieses Kontextes führt ein intelligenter Agent eine Aktion A_t in Bezug auf den aktuellen Zustand zum Zeitpunkt t aus und erhält als Ergebnis dieser Aktion eine Belohnung R_{t+1} . In der Folge beobachtet der Agent einen neuen Zustand S_{t+1} und führt

basierend auf dem neuen Zustand die nächste Aktion aus. Der iterative Prozess setzt sich fort, bis der Agent durch Maximierung einer kumulativen Belohnung zu einer optimalen Strategie konvergiert (Shavandi & Khedmati, 2022).

Bei der simultanen Interaktion mehrerer Agenten in einer gemeinsamen Umgebung zeigt sich eine gewisse Ähnlichkeit zum Verhalten eines einzelnen Agenten, wobei jedoch Interaktionen zwischen den Agenten zu beobachten sind. Diese Interaktionen können entweder kooperativ oder kompetitiv sein (Bus, oniu et al., 2006). In Anbetracht der Tatsache, dass die Komplexität des Multi-Agenten-RL den Rahmen dieser Studie übersteigt und der Interaktionsprozess zwischen Agenten und Umgebung im Multi-Agenten-RL im Wesentlichen dem des Einzelagenten entspricht, beschränkt sich diese Arbeit in Kapitel Vier auf den Interaktionsprozess eines einzelnen Agenten mit der Umgebung. Dadurch soll den Lesern ein besseres Verständnis für die Anwendung des Verstärkungslernens im Kontext der algorithmischen Handelsforschung vermittelt werden.




Abbildung 5: Reinforcement Learning Prozess (Shavandi & Khedmati, 2022, S. 5)

Ein spezifischer Ableger des RL ist das DRL. In diesem Kontext stellt die Q-Funktion den erwarteten kumulativen Ertrag dar, den ein Agent durch die Ausführung einer bestimmten Aktion in einem gegebenen Zustand und dem anschließenden Verfolgen einer bestimmten Strategie erzielen kann. Q-Netzwerke zielen darauf ab, die optimale Aktionsauswahlstrategie eines Agenten zu erlernen, indem sie den Q-Wert (erwarteter kumulativer Ertrag) für verschiedene Zustand-Aktions-Paare schätzen. Die Struktur des Q-Netzwerks stellt einen zentralen Bestandteil von DRL-Algorithmen dar und übt einen maßgeblichen Einfluss auf die Endergebnisse des Modells aus (Huang, Zhou, et al., 2024a).

Q-Learning ist eine modellfreie *Off-Policy*-Methode von RL, bei der der Agent durch Interaktion mit der Umgebung die optimale Zustand-Aktions-Wert-Funktion erlernen möchte. In diesem Kontext wird eine sogenannte Q-Tabelle $Q[S, A]$ geführt, welche die Q-Werte für jedes Zustand-Aktions-Paar enthält (Chakole et al., 2021).

3 Methodik

Im vorliegenden Kapitel erfolgt eine Darlegung des methodischen Vorgehens innerhalb der vorliegenden Arbeit. In diesem Kapitel wird, ausgehend von der Formulierung der Forschungsfragen

im Abschnitt 1.3, der in Abschnitt 1.3 beschriebene dritte Schritt des Leitlinien-Plans einer systematischen Literaturrecherche nach Vom Brocke et al. (2009) verfolgt. Im Folgenden wird zunächst der Aufbau der Suchstrategie dargelegt, bevor auf deren Grundlage der Eingrenzungsprozess beschrieben wird. Abschließend wird ein Überblick über die finale Literatur gegeben.

3.1 Aufbau der Suchstrategie

Die Suchstrategie stellt eine wesentliche Grundlage für die Identifizierung passender und relevanter Literatur dar. Im Folgenden erfolgt eine transparente Darstellung des Suchprozesses. Die Basis der Literaturrecherche bilden wissenschaftliche Datenbanken. Die Nutzung einer einzigen Datenbank wäre zu einseitig und könnte das gesamte Spektrum der Forschung nicht vollständig abdecken. Daher wurde die Recherche auf drei Datenbanken ausgedehnt. Die in dieser Arbeit verwendeten Datenbanken "Scopus", "EBSCOhost" und "DBLP" wurden mit zwei unterschiedlichen Strategien durchsucht, um eine einheitliche Vorgehensweise und Vergleichbarkeit der Ergebnisse sicherzustellen. Für die Datenbanken "Scopus" und "EBSCOhost" wurden identische Suchstrings verwendet, da diese beiden Datenbanken eine ähnliche Formatunterstützung bieten.

Die Anwendung identischer Suchstrings bei "DBLP" resultierte jedoch in keinerlei brauchbaren Resultaten. Daher wurden für die Suche in "DBLP" allgemeinere Suchbegriffe eingesetzt, um sicherzustellen, dass relevante Studien für die vorliegende Forschung identifiziert werden konnten. Die Anwendung einer breiteren Suchstrategie ermöglichte insbesondere in der Anfangsphase der Forschung eine Betrachtung der Forschungsfrage aus unterschiedlichen Perspektiven.

Die verwendeten Suchbegriffe umfassten im Wesentlichen die allgemeinen Begriffe "Artificial Intelligence" und "Algorithmic Trading". Um eine bessere Übersicht zu gewährleisten und die Suchergebnisse einzugrenzen, wurden die Suchstrategien in den verschiedenen Datenbanken regelmäßig angepasst und spezifischer auf den jeweiligen Forschungsbereich abgestimmt. Die untersuchten Datenbanken weisen Unterschiede hinsichtlich der Möglichkeiten auf, spezifische Suchfelder anzupassen und die Recherche mit speziellen Filterfunktionen zu konfigurieren. In Scopus wurde die Filtermaske "Article Title, Abstract and Keywords" verwendet, während in EBSCOhost und DBLP die Filtermaske "All Fields" zum Einsatz kam.

Die in den drei Datenbanken erzielten Suchergebnisse basieren auf englischsprachigen Fachartikeln. Die Verwendung deutscher Begriffe bzw. der deutschen Übersetzungen der Suchbegriffe resultierte in keiner signifikanten Steigerung der relevanten Ergebnisse. Aus diesem Grund wurden im weiteren Verlauf Suchen mit deutschen Begriffen nicht berücksichtigt.

3.2 Eingrenzungsprozess

Im Rahmen der Eingrenzung der Suchergebnisse erfolgte eine nacheinander durchgeführte, systematische Durchsicht der in Abschnitt 3.1 vorgestellten Datenbanken, um relevante Literatur zu identifizieren. Aufgrund des signifikanten Aufschwungs der Forschung im Bereich KI, welcher im Jahr 2019 durch das Aufkommen von *Open-Source*-Sprachmodellen wie GPT-2 zu verzeichnen war, wurden in dieser Studie bei der Literaturrecherche in den verschiedenen Datenbanken nur Beiträge ab dem Jahr 2019 berücksichtigt. Die Vorgehensweise ermöglicht es, sowohl

traditionelle KI-Technologien, die auf ANN basieren, als auch neue generative KI-Technologien, die auf großen Sprachmodellen beruhen, in die Untersuchung einzubeziehen.

Die Datenbank "DBLP" fungierte als Ausgangspunkt der Suche. Am 10.09.2024 wurde eine Suche mit dem Suchstring "Algorithmic Trading" in sämtlichen Suchfeldern durchgeführt, was zu 97 Ergebnissen führte.

Die hohe Anzahl an Ergebnissen sowie die eher unspezifische Suche erforderten eine weitere Eingrenzung der Ergebnisse für eine detaillierte Analyse. Eine erneute Suche mit den Suchstrings "Algorithmic Trading" AND "AI" am 10.09.2024 ergab 57 Treffer. Die ermittelte Anzahl an Ergebnissen war jedoch nicht ausreichend, um als Grundlage für ein Abstract- oder Titelscreening zu dienen, sodass eine Verfeinerung des Suchprozesses erforderlich war.

Die zweite Datenbank, "Scopus", lieferte am 10.09.2024 unter Verwendung desselben Suchstrings 28 Ergebnisse, wobei keine Dopplungen auftraten. Von den 28 Ergebnissen waren bereits 12 in der vorherigen Übersicht enthalten, sodass sich die Gesamtzahl der relevanten Texte von 57 auf 73 erhöhte.

Als letzte Datenbank wurde „EBSCOhost“, insbesondere die Teildatenbank „Business Source Complete“, durchsucht. Mithilfe der Suchstrings „("Artificial Intelligence" OR "AI" OR "Machine Learning") AND ("Algorithmic Trading" OR "Automated Trading") AND ("Best Practices" OR "Methodologies" OR "Strategies")“ und der Filtereinstellung „All Fields“ erzielte die Suche am 10.09.2024 insgesamt 16 Treffer. Nach der Entfernung einer Dopplung wurden die neuen Artikel zur gesammelten Übersicht hinzugefügt. 7 der 16 neuen Artikel waren bereits in der Liste vorhanden, wodurch die aktualisierte Übersicht schließlich 82 relevante Texte umfasste.

Durch die Suchprozesse in den drei unterschiedlichen Datenbanken konnten somit 82 Ergebnisse in die Gesamtübersicht aufgenommen werden. Die einzelnen Suchvorgänge sowie die erzielten Treffer sind in der Tabelle 1 dargestellt.

Im Rahmen der durchgeführten Recherche wurde als letzte Datenbank "EBSCOhost", insbesondere die Teildatenbank "Business Source Complete", analysiert. Die Suche wurde mit den folgenden Suchstrings durchgeführt: " ("Artificial Intelligence" OR "AI" OR "Machine Learning") AND ("Algorithmic Trading" OR "Automated Trading") AND ("Best Practices" OR "Methodologies" OR "Strategies")". Die durchgeführte Suche am 10.09.2024 erzielte unter Verwendung der Filtereinstellung "All Fields" insgesamt 16 Treffer. Im Anschluss an die Eliminierung einer Duplikation wurden die neuen Artikel zur aggregierten Übersicht hinzugefügt. Sieben der insgesamt 16 neu identifizierten Artikel waren bereits in der ursprünglichen Liste enthalten, sodass die aktualisierte Übersicht schließlich 82 relevante Texte umfasste.

Infolge der durchgeführten Suchprozesse in den drei unterschiedlichen Datenbanken konnten insgesamt 82 Ergebnisse in die Gesamtübersicht aufgenommen werden. Die einzelnen Suchvorgänge sowie die erzielten Treffer sind in der nachfolgenden Tabelle 1 dargestellt.

Tabelle 1: Suchvorgänge in Datenbanken

Datum	DB	Suchtext	Suchfeld	Treffer	Neu	Summe
10.09.2024	DBLP	„algorithmic trading“ AND „AI“	TI, ABS, KEY	57	57	57
10.09.2024	Scopus	„algorithmic trading“ AND „AI“	TI, ABS, KEY	28	16	73
10.09.2024	EBSCOhost	("Artificial Intelligence" OR "AI" OR "Machine Learning") AND ("algorithmic trading" OR "automated trading") AND ("best practices" OR "methodologies" OR "strategies")	TI, ABS, KEY	16	9	82

Nachdem die Grundlage für die Untersuchung geschaffen worden war, wurde mit dem ersten Schritt des Eingrenzungsprozesses begonnen. Im Rahmen des Titelscreenings erfolgte eine Prüfung der Relevanz der 82 identifizierten Ergebnisse für das Forschungsthema. Artikel, bei denen kein klarer Bezug zu algorithmischem Handeln oder KI erkennbar war, wurden von der weiteren Untersuchung ausgeschlossen. Des Weiteren wurden Titel entfernt, die auf zu spezifische Themenbereiche hinwiesen, beispielsweise reine Mathematik oder Programmierung, sodass eine allgemeine Übertragbarkeit nicht gewährleistet werden konnte. Infolge der Verwendung diverser Suchbegriffe wies die Ergebnisliste eine hohe Diversität hinsichtlich ihres Zwecks und Inhalts auf. In der Konsequenz wurden 51 Artikel für die weitere Analyse selektiert.

Im zweiten Schritt wurden die 51 ausgewählten Texte einem Abstractscreening unterzogen. Der Fokus lag erneut darauf, Inhalte zu identifizieren, die für das Forschungsthema relevante Aspekte behandeln. Des Weiteren wurden Texte, deren Abstracts nach genauerer Betrachtung als themenfremd oder zu spezifisch eingestuft wurden, ebenfalls aus der Liste entfernt. Nach Abschluss dieses Schritts verblieben 34 Artikel für den letzten Eingrenzungsschritt.

Im dritten Schritt erfolgte eine Volltextprüfung der verbleibenden 34 Artikel, bei der sieben weitere Texte ausgeschlossen wurden. Die finale Übersicht umfasste somit 27 Artikel. Im Anschluss wurde die Liste um sechs zusätzliche Artikel ergänzt, die im Rahmen einer Rückwärtssuche (RW-Suche) identifiziert wurden. Somit umfasst die finale Übersicht insgesamt 33 Artikel. Der gesamte Eingrenzungsprozess wird in Abbildung 6 veranschaulicht.

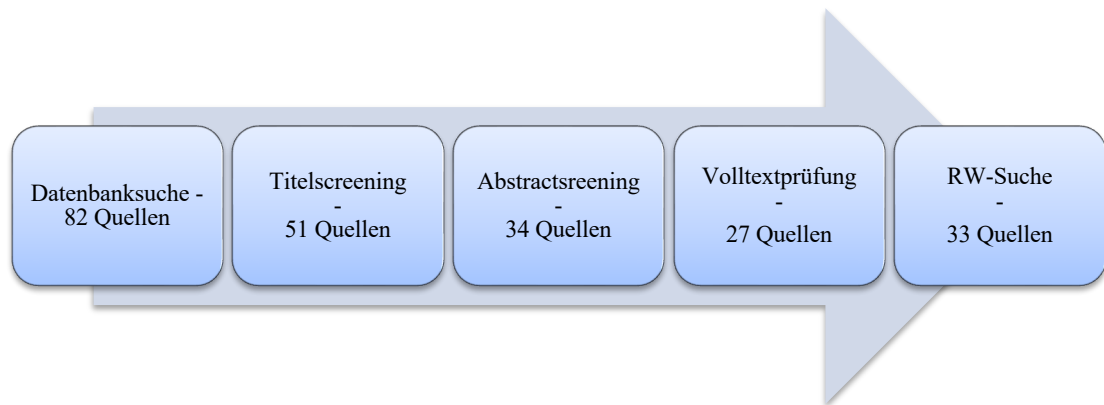


Abbildung 6: Eingrenzungsprozess

4 Ergebnisse

4.1 Eine automatisierte Exit- und Wiedereinstiegsstrategie

In der Folge der Entwicklung des algorithmischen Handels wurden zunächst Methoden aus der Statistik und Mathematik in der Praxis angewendet. Mit dem Fortschritt der KI-Technologien sowie der entsprechenden Hardware wurden mathematische und statistische Ansätze zunehmend durch neue KI-basierte Techniken ergänzt. Daher ist es im Rahmen dieser Studie notwendig, zunächst die konventionellen Methoden des algorithmischen Handels zu erörtern, bevor die entsprechenden KI-Werkzeuge präsentiert werden.

In der konventionellen Forschung und Praxis des algorithmischen Handels findet die sogenannte *Price Jump Method* häufig Anwendung. Diese Methode kann im Bereich des Finanzrisikomanagements und der Analyse von Marktvolatilität angewendet werden. *Price Jumps* im algorithmischen Handel beziehen sich auf plötzliche Preisveränderungen innerhalb kurzer Zeiträume, die die Volatilität des Marktes widerspiegeln (Koegelenberg & van Vuuren, 2024)

Koegelenberg & van Vuuren (2024) stellten eine neuartige automatisierte Exit- und Wiedereinstiegsstrategie vor, deren primäres Ziel Preisveränderungen rechtzeitig vorherzusehen und anschließend die Marktvolatilität zu analysieren ist. Ein geeigneter Zeitpunkt wurde anschließend für den Wiedereinstieg identifiziert. *Intraday*-Händler nutzen kleine Transaktionen und *intraday* Preisschwankungen, um Portfolio-Renditen zu akkumulieren, ohne über Nacht Positionen offen zu halten. Da eine hohe Marktliquidität für den Intraday-Handel erforderlich ist, wird der Devisenmarkt (Forex) häufig als bevorzugtes Asset gewählt (Koegelenberg & van Vuuren, 2024)

Bei *Value-at-Risk* (VaR) -Analysen wird angenommen, dass der Wert von Vermögenswerten ausschließlich von deren Preisen abhängt und nicht durch das Handelsvolumen oder die Art der Transaktionen (Kauf oder Verkauf) beeinflusst wird (Gourieroux & Jasiak, 2010). Mithilfe von VaR-Analysen lässt sich der maximal zu erwartende Verlust eines Portfolios für die kommenden Handelstage berechnen.

Ein weiterer in dieser automatischen Exit- und Wiedereinstiegsstrategie verwendeter Ansatz ist die Entropie. Entropie ist ein Indikator für das Maß an Unordnung oder Chaos eines Systems. Im

Kontext der Finanztheorie wird Entropie häufig mit der Wahrscheinlichkeitstheorie in Verbindung gebracht und dient als Maß für die Unsicherheit eines Systems. Generell findet Entropie Anwendung bei der Portfoliowahl und der Auswahl von Vermögenswerten (Koegelenberg & van Vuuren, 2024).

Die automatisierte Exit- und Wiedereinstiegsstrategie besteht aus zwei Phasen, wie in der Abbildung 7 dargestellt wird. In Phase 1 wird eine VaR-Analyse durchgeführt, um Preisveränderungen zu identifizieren. Anschließend wird in Phase 2 eine Entropie-Analyse durchgeführt, um einen geeigneten Wiedereinstiegspunkt in den Markt zu bestimmen (Koegelenberg & van Vuuren, 2024). In zwei Fallstudien erzielten Koegelenberg & van Vuuren (2024) positive Ergebnisse, wobei sie den potenziellen Verlust durch Marktvolatilität in den Finanzmärkten in monetären Werten quantifizierten.

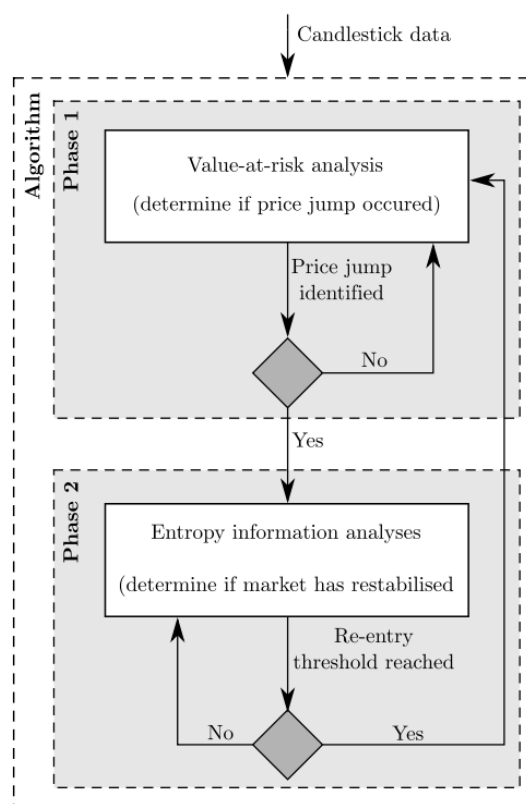


Abbildung 7: Ein Prozessdiagramm der automatisierten Preissprungausstiegs- und Wiedereinstiegsstrategie (Koegelenberg & van Vuuren, 2024, S. 13)

4.2 Machine Learning

In den recherchierten wissenschaftlichen Arbeiten über KI und algorithmischen Handel verwenden einige Forscher konventionelle Methoden des maschinellen Lernens für den algorithmischen Handel. Maschinelle Lernalgorithmen haben sich als nützliche Werkzeuge zur Entwicklung von Handelsstrategien erwiesen, die Markteffizienzen optimieren können (Gurung et al., 2024). Aufgrund unterschiedlicher Auffassungen über algorithmischen Handel vertreten manche Forscher die Ansicht, dass der Einfluss der KI-Technologie auf den algorithmischen Handel darin liegt, dass relevante Indikatoren des Finanzmarktes mithilfe von maschinellen Lernalgorithmen

erfasst werden können (Barucci et al., 2021). Andere Forscher versuchen, mithilfe verschiedener Algorithmen Trends auf dem Finanzmarkt vorherzusagen. Doch mit zunehmender Marktkomplexität nimmt auch die Schwierigkeit der Marktprognose zu (Koegelenberg & van Vuuren, 2024). Allerdings gibt es auch gegenteilige Meinungen. Manche Wissenschaftler sind der Ansicht, dass die alleinige Nutzung von prädiktiver Analyse zur Vorhersage von Markttendenzen oder der zukünftigen Kursentwicklung einzelner Aktien unzureichend ist und durch intelligenteren Methoden ergänzt werden sollte, um bessere Investitionsstrategien zu erzielen (Huang, Zhou, et al., 2024a; Sevastjanov et al., 2024).

Um präzise Vorhersagen zu treffen, wurden nichtlineare Prognosemodelle auf Basis des maschinellen Lernens erforscht und angewandt. Diese gängigen Prognosemodelle lassen sich in zwei Kategorien unterteilen: Klassifikatoren (wie z.B. SVM) und Regressoren (wie *Support Vector Regression*, SVR) (Henrique et al., 2023), die für die Vorhersage diskreter bzw. kontinuierlicher Daten eingesetzt werden. Gurung et al. (2024) entwickelten mithilfe von Python und den Algorithmen *Ridge Regression*, *Ada-Boost*, *Light-GBM*, *XG-Boost*, *Linear Regression* und *Cat-Boost* aus der *Scikit-Learn*-Bibliothek spezifische algorithmische Handelsstrategien für den US-Aktienmarkt. Die Ziele des algorithmischen Handels bestehen darin, fortgeschrittene Datenanalyse und Rechenleistung zu nutzen, um profitable Handelsmöglichkeiten und Trends zu identifizieren, die für menschliche Händler zu komplex oder zu schnell sind, um sie zu erkennen und darauf zu reagieren (Gurung et al., 2024).

4.2.1 Klassifikationsalgorithmen zur Markttrendprognose

Die Vorhersage zukünftiger Trends eines bestimmten Finanzmarktes durch Klassifikationsalgorithmen kann den Händlern profitable Chancen bieten. Tatsächlich ist auch die Marktrichtung (*Market Directional*) eine Art des algorithmischen Handels (Malik, 2023). Richtungsorientierter Handel bedeutet, dass Anleger basierend auf ihren Erwartungen an die Preisentwicklung des Marktes handeln. Wenn ein Händler beispielsweise einen Anstieg durch das Ergebnis der Klassifikation der zukünftigen Preise erwartet, kauft er Vermögenswerte, um sie bei einem Preisanstieg zu verkaufen und Gewinne zu erzielen (sog. *Long-Position*). Wenn ein Händler hingegen einen Preisverfall durch Klassifikation erwartet, leiht er sich Vermögenswerte, verkauft diese auf dem Markt und kauft sie später günstiger zurück, um sie zurückzugeben (sog. *Short-Position*).

Henrique et al. (2023) verglichen auf zehn Aktienmärkten verschiedener Länder die Leistung von SVM, RF und Naive-Bayes (NB) als Prognosealgorithmen zur Vorhersage der Preisrichtung des aktuellen Tages sowie der Preisrichtung des Folgetages. Diese Prognosealgorithmen nutzen technische Indikatoren als unabhängige Variablen, darunter *Simple Moving Average* (SMA), *Weighted Moving Average* (WMA), *Exponential Moving Average* (EMA), *Momentum*, *William R%*, *Moving Average Convergence Divergence* (MACD), *Relative Strength Indicator* (RSI), *Accumulation/Distribution Oscillator* (ADO) und *Commodity Channel Index* (CCI) (Henrique et al., 2023). Diese technischen Indikatoren werden anhand der Schlusskurse jedes Handelstags berechnet. Die abhängige Variable in den Modellen ist die Preisrichtung, d.h. Aufwärts- oder Abwärtstrend (Henrique et al., 2023).

Die Ergebnisse der Studie von Henrique et al. zeigen jedoch, dass die oben genannten Modelle mit mehreren technischen Indikatoren als unabhängigen Variablen im Wesentlichen unbrauchbar sind, um wertvolle Informationen für Handelsentscheidungen zur Richtung des Folgetages zu liefern. In ihrer Forschung zeigten diese Klassifikationsmodelle keine signifikanten Vorteile gegenüber einem zufälligen Modell bei der Vorhersage von Marktbewegungen.

4.2.2 Regressionsalgorithmen zur Markttrendprognose

Malik (2023) verwendete auf Regression basierende maschinelle Lernmodelle, RF und SVM, zur Vorhersage von Preistrends im *Bitcoin-Futures-Markt* anhand quantitativer Indikatoren. Die hohe Volatilität und das kontinuierliche Handelsvolumen bieten gute Möglichkeiten für hochfrequenten algorithmischen Handel (Malik, 2023), insbesondere im Vergleich zum Aktienmarkt. Da die Volatilität nicht direkt aus den Renditen der Futures-Preise abgeleitet werden kann, nutzte Malik einen Proxy zur Messung der historischen realisierten Volatilität, definiert als Varianz der Renditen zum Zeitpunkt t , also das Quadrat der Renditen.

Im RF-Modell bestimmt der Mittelwert der Ausgaben aller Entscheidungsbäume das endgültige Ergebnis des Modells. Bei der Konstruktion jedes Entscheidungsbaums wird durch zufällige Auswahl von Beobachtungen aus dem Trainingsdatensatz mit Zurücklegen eine Bootstrap-Stichprobe erstellt. Die zufällige Auswahl der Merkmale sorgt für eine geringe Korrelation zwischen den Bäumen und reduziert so das *Overfitting*. Zur Vorhersage des Quadrats der bedingten Volatilität wurden verzögerte Quadrate der Renditen als Eingabe für das Modell verwendet. Im SVM-Modell wurden ebenfalls verzögerte Werte verwendet, um die quadrierte bedingte Volatilität zu prognostizieren. SVM teilt den Eingaberaum mithilfe von Hyperebenen auf und nutzt dabei Kernel-Funktionen (Malik, 2023).

4.2.3 Cluster-Algorithmen

Chakole et al. (2021) entwickelten im Rahmen eines algorithmischen Handelsmodells auf Basis von RF innovativ eine unüberwachte Lernmethode, das *K-Means-Clustering*, zur Darstellung des Verhaltens des Aktienmarktes als die Umgebung durch eine begrenzte Anzahl von Zuständen. In ihrem Modell wird angenommen, dass sich die Historie wiederholt, d.h., das aktuelle Muster einer Handelssitzung kann dem Muster einer Sitzung in der Vergangenheit ähneln. Daher sollten Anleger in der Lage sein, die optimale Investitionsentscheidung aus einer früheren ähnlichen Situation zu identifizieren und sie auf eine aktuelle, ähnliche Situation anzuwenden (Chakole et al., 2021).

Die typischen drei Muster oder Trends einer Handelssitzung umfassen Aufwärtstrend, Abwärtstrend und Seitwärtstrend. Innerhalb dieser drei Muster gibt es weitere Submuster. Die Daten historischer Handelssitzungen können daher in N Gruppen oder Cluster unterteilt werden. Zwei Handelssitzungen in derselben Gruppe teilen bestimmte Merkmale, während Sitzungen in unterschiedlichen Gruppen Unterschiede aufweisen. Diese Gruppen oder Cluster werden aus den historischen Sitzungsdaten mithilfe des *K-Means-Clusterings* gebildet (Chakole et al., 2021).

4.3 Deep Learning

In jüngster Zeit entwickelt sich der algorithmische Handel mit Finanzanlagen durch den Aufstieg von DL rasch weiter. Als Teil einer größeren Familie von maschinellen Lernmethoden wird DL häufig verwendet, um Aktienpreise oder Trendbewegungen vorherzusagen und so Finanzhandelsstrategien zu entwickeln (Huang & Song, 2023).

Im Vergleich zu Methoden des maschinellen Lernens ist die Anzahl der Studien, die durch DL hochabstrakte Informationen aus sequenziellen Handelsdaten extrahieren (Huang & Song, 2023), deutlich größer. Forscher setzen dabei besonders auf DL-Modellen wie LSTM und verschiedene Varianten, z. B. BiLSTM, um Merkmale zu extrahieren und anschließend ein tiefes Lernmodell (z. B. MLP, CNN und LSTM) zu trainieren, um die Kapitalmarkttrends vorherzusagen.

Huang & Song (2023) kombinierten ein MLPs, das auch bekannt als DNN ist, mit Methoden von RL. Die zwanzig Eingangsmerkmale des neuronalen Netzwerks wurden durch eine vollständig verbundene Schicht und die Aktivierungsfunktion *tanh* in einen Output im Bereich von $[-1, 1]$ umgewandelt. Das Extrahieren von Informationen aus Zeitreihendaten ist jedoch eine komplexe Aufgabe. Aufgrund der Leistungsbeschränkungen von MLP kann es die Informationen aus sequenziellen Daten nicht vollständig erfassen (Huang & Song, 2023). Daher ist das strukturell einfache MLP-Modell nicht die erste Wahl für algorithmischen Handel. Es wurde in mehreren Studien beobachtet, dass MLP-basierte Modelle eine geringere durchschnittliche jährliche Rendite als die durchschnittliche Marktwachstumsrate bringen (Yilmaz et al., 2024).

4.3.1 CNN

Wie bereits erwähnt, erfordern algorithmische Handelsmodelle im Bereich von ML und DL häufig historische Daten aus den Finanzmärkten als Grundlage für das Modelltraining. Yilmaz et al. (2024) stellten die Repräsentationsfähigkeit von Finanzzeitreihendaten infrage, da diese Daten nicht alle Informationen über den Finanzmarkt enthalten. Zeitreihendarstellungen können zwar das Verhalten einer Entität in Bezug auf die Zeit erfassen, jedoch nicht deren Beziehung zu anderen Entitäten. Graphen hingegen eignen sich am besten zur Darstellung relationaler Informationen in Daten, was besonders wertvoll in Datensätzen ist, die aus voneinander abhängigen Entitäten bestehen (Yilmaz et al., 2024). Da ein Graph typischerweise als *Adjazenzmatrix* dargestellt wird, eignet er sich ideal, weil CNN auf die Extraktion von Merkmalen aus zweidimensionalen Daten spezialisiert ist (Yilmaz et al., 2024).

In der Studie von Yilmaz et al. wurde eine asymmetrische Adjazenzmatrix verwendet, um ein gerichtetes Modell darzustellen (Yilmaz et al., 2024). Ein Vorteil dieses gerichteten Graphen liegt darin, dass er nicht nur die Korrelation zwischen verschiedenen Aktien quantifizieren kann, sondern auch durch die im Graphen durch die Kanten dargestellten Gewichte den Einfluss des historischen Preises einer Aktie auf den aktuellen Preis einer anderen Aktie ausdrückt (Yilmaz et al., 2024). Die Gewichte der Kanten wurden in jedem Graph-Modell unterschiedlich konstruiert. Daher lässt sich behaupten, dass sie unterschiedliche Aspekte der Beziehung zwischen Aktien erfassen können (Yilmaz et al., 2024).

4.3.2 LSTM & BiLSTM

Um langfristige und kurzfristige Informationen aus den Zeitreihendaten des Finanzmarktes effizienter zu erfassen, wurde das LSTM mit seiner komplexeren Struktur eingeführt. Das BiLSTM, bestehend aus zwei LSTM-Modellen mit entgegengesetzten Richtungen, kann die Informationen in beide Richtungen voll ausschöpfen, um effektivere Informationen zu erfassen. Das LSTM oder BiLSTM wird verwendet, um die Entscheidungsfunktion zu approximieren, die den Zustandsraum auf den Handlungsraum abbildet und dann den Sharpe-Ratio durch die Gradienten Anpassung maximiert, um die jeweils beste Handelsstrategie zu generieren (Huang & Song, 2023).

Wie in Abbildung 4 zur LSTM-Struktur dargestellt, hängt der Zustand der verborgenen Schicht des ANNs nicht nur vom aktuellen Eingang ab, sondern auch vom verborgenen Zustand des vorherigen Zeitpunkts. Dies ist auch der Grund, warum das LSTM-Modell und seine Variationen in der Lage sind, aus Zeitreihendaten unterschiedlicher Länge sowohl kurz- als auch langfristige Informationen über Finanzmärkte zu extrahieren. Diese Art von LSTM-basierten Modellen wird von Forschern häufig als Merkmalsextraktor in DRL-Modellen eingesetzt. Daher werden die Details dieser Modelle ausführlich in Kapitel 4.4 dieser Studie erläutert.

4.4 Deep Reinforcement Learning

Die Effektivität der zuvor erwähnten Methoden von DL hängt hauptsächlich von der Vorhersagegenauigkeit ab; außerdem ist tiefes Lernen aufgrund seiner inhärenten *Overfitting* beschränkt (Huang & Song, 2023). Darüber hinaus können Methoden von DL die für algorithmischen Handel erforderliche kontinuierliche und schnelle Entscheidungsfindung nicht bewältigen. Daher werden Methoden von ML und DL häufig in Kombination mit RL eingesetzt. Im Vergleich zu prognosebasierten Methoden ermöglicht das sog. DRL die Abbildung vom Zustandsraum zum Aktionsraum durch kontinuierliches und selbstgesteuertes Online-Lernen (Huang & Song, 2023). Das Prinzip von RL besteht darin, dass ein Agent kontinuierlich mit seiner Umgebung interagiert und die optimale Handelsregel erlernt, um seine Handelsstrategie zu verbessern (Aloud & Alkhamees, 2021).

RL wird zunehmend für algorithmischen Handel in verschiedenen Finanzmärkten wie dem Devisenmarkt, Aktienmarkt und Terminmarkt angewandt. In den analysierten Publikationen ist RL eine der am intensivsten untersuchten Methoden. Die Komplexität bei der Entwicklung und Anwendung verstärkungslernender Modelle für Forschung und Praxis ist jedoch nicht zu unterschätzen.

Die Festlegung einer spezifischen Handelsregel für einen bestimmten Zeitpunkt ist eine zentrale Forschungsfrage im Handel an Finanzmärkten. Ein intelligenter und dynamischer algorithmischer Handelsansatz, der durch aktuelle Muster einer gegebenen Zeitreihe gesteuert wird, kann helfen, dieses Problem zu lösen. RL kann dynamischen algorithmischen Handel optimieren, indem die Preis-Zeitreihe als Umgebung betrachtet wird (Aloud & Alkhamees, 2021).

DRL hat bemerkenswerte Erfolge bei der Lösung komplexer sequenzieller Entscheidungsprobleme erzielt, weshalb immer mehr Forschungen auf die Kombination von DRL und Investitionsentscheidungen fokussieren. Es ermöglicht die direkte Merkmalsextraktion aus

BiLSTM wie in der Abbildung 9, um automatisch höherstufige abstrakte Merkmale aus sequenziellen Handelsdaten zu extrahieren und dann in einem RL-Rahmenwerk durch Interaktion mit der Umgebung optimale Handelsstrategien zu generieren (Huang & Song, 2023).

Ein auf BiLSTM basierender Ansatz kann in den US-amerikanischen Aktienindizes andere Methoden übertreffen, da BiLSTM die bidirektionale Informationsverarbeitung ermöglicht und so effizientere Informationen aus den Daten extrahiert (Huang & Song, 2023).



Abbildung 9: Die Struktur von DNN/LSTM/BiLSTM-RL (Huang & Song, 2023, S. 1943)

Zunächst wurden DNN, LSTM und BiLSTM jeweils angewandt, um Entscheidungsfunktionen zu ersetzen und den Zustandsraum in den Aktionsraum abzubilden. Anschließend wurde das Sharpe Ratio mithilfe des Gradientenanstiegs maximiert, um optimale Handelsstrategien zu generieren (Huang & Song, 2023).

Händler erlernen Strategien durch ein Verfahren von Versuch und Irrtum, wobei sie Aktionen ausführen und je nach Ergebnis positive oder negative Verstärkung erhalten. Eine Handelsleistungsfunktion $U(\theta)$, wie Gewinn, Nutzen oder risikoadjustierte Rendite, wird verwendet, um die Parameter des Handelssystems θ direkt zu optimieren. Daher wird RL eingesetzt, um die Gewichungen in einem ANN (wie MLP, LSTM und BiLSTM) über den Gradientenanstieg in der Nutzenfunktion $U(\theta)$ anzupassen (Huang & Song, 2023).

Die grundlegenden Elemente zur Konstruktion eines algorithmischen Handelssystems basierend auf DRL sind wie folgt:

- **θ :** Parameter des DL-Modells
- **State:** Alle Marktdaten (z. B. Preis zum Zeitpunkt t ist p_t) für zugrunde liegende Finanzanlagen bilden den Umweltzustand. Hier werden die Renditen der letzten M Handelstage als Eingaben des Agenten zum Zeitpunkt t integriert, definiert als $x_t = [r_t, \dots, r_{t-M}]$.
- **Action:** Der Agent im Handelssystem versucht, das Sharpe-Ratio in der gegebenen Zeitreihe (State) zu maximieren. F_t wird durch den Output des Handelssystems berechnet und repräsentiert die Handelsentscheidung zum Zeitpunkt t .
 - Wenn $F_t = -1$, wird ein Short-Sell ausgeführt.

- Wenn $F_t = 0$, führt das Handelssystem keine Aktion aus.
- Wenn $F_t = 1$, wird ein Long-Buy ausgeführt.
- **Reward Function:** Die Rendite R_t eines Handelssystems wird am Ende des Zeitintervalls $(t, t + 1]$ realisiert und umfasst Gewinn oder Verlust sowie die Transaktionskosten.
- **Utility Function:** Ein Handelssystem kann durch Maximierung einer Leistungsfunktion, wie der Nutzenfunktion von Gewinn, Vermögen oder einer risikoadjustierten Rendite wie dem Sharpe-Ratio, optimiert werden.

4.4.3 Directional Change Reinforcement Learning

Ein wichtiger Schritt bei der Entwicklung einer dynamischen algorithmischen Handelsstrategie durch RL ist die umfassende Darstellung der Umweltzustände (Aloud & Alkhamees, 2021). Um diesen Prozess zu gewährleisten, entwickelten Aloud & Alkhamees (2021) den sogenannten *Directional Change* (DC)-RL, der das Q-Learning-Verfahren zur Optimierung der Handelsprozesse verwendet. Eine Innovation dieser Methode besteht darin, dass die Ereignisse der Richtungsänderung (DC) unter intrinsischer Zeit als alternative Analysemethode für Preiszeitreihen verwendet werden, um zyklische Muster in diesen Preiszeitreihen zu erfassen (Aloud & Alkhamees, 2021).

Das DCRL-Modell wird als Alternative zu herkömmlichen Zeitreihenanalysen zur Darstellung der Umweltzustände angesehen. Herkömmliche Methoden basieren meist auf festen Zeitintervallen, während das DCRL-Modell Preiszeitreihen in intrinsischen Zeitintervallen analysiert. Das Modell erlernt dabei Zustände der Preiszeitreihe, um optimale dynamische Schwellenwerte für die DC-Ereignisanalyse zu identifizieren (Aloud & Alkhamees, 2021).

Der DCRL-basierte algorithmische Handel umfasst zwei Hauptkomponenten. Zunächst wird die DC-Ereignismethode mit einem dynamischen DC-Schwellenwert verwendet, um die Umweltzustände des Marktes zu identifizieren und darzustellen. Anschließend trifft der RL-Entscheidungsalgorithmus Entscheidungen und führt entsprechende Handelsaktionen aus. Richtungsänderungen umfassen zwei Arten von Ereignissen: Aufwärtsbewegungen, die identifiziert werden, sobald die Preisänderung größer oder gleich einem festen Schwellenwert ist, und Abwärtsbewegungen, die identifiziert werden, wenn die Preisänderung kleiner oder gleich einem festen Schwellenwert ist (Aloud & Alkhamees, 2021).

4.4.4 Einbindung von Sentimentanalyse in RL

Merkmale auf Basis von Preisbewegungen können als minimale Informationen zur Modellierung des Zustandsraums angesehen werden, insbesondere unter Einbeziehung der neuesten Preishistorie und einer Reihe technischer Indikatoren, um die wahrscheinliche zukünftige Entwicklung des Aktienkurses abzuleiten (Tabaro et al., 2024). Um die Grenzen rein technischer algorithmischer Handelsstrategien zu überwinden, erweiterten Tabaro et al. (2024) den Zustand des Agenten durch Sentimentanalyse der Finanzberichte von Tesla. Sie simulierten den Aktienmarkt und testeten das mit Sentimentanalyse angereicherte tiefverstärkungslernende Modell, wobei sie

feststellten, dass der Agent in der angereicherten Umgebung seine kumulierte Belohnung im Testzeitraum um bis zu 70 % steigern konnte (Tabaro et al., 2024).

Zur Konstruktion der angereicherten RL-Umgebung fügte Tabaro et al. dem traditionellen Zustandsspektrum neue Merkmale hinzu, die durch Sentimentanalyse auf Basis der Kosinussimilarität berechnet wurden und Kategorien wie *Negativ*, *Positiv*, *Uncertainty*, *Litigious*, *Constraining* und *Interesting* umfassen. Zur Sicherstellung, dass alle Merkmale zur Modellleistung beitragen können, wurden alle Merkmale im Fenster auf eine einheitliche Skala normiert.

Der Zustandsarray wurde anschließend an die Eingabeanforderungen des LSTM-Netzwerks angepasst, welches ein dreidimensionales Array mit den Dimensionen (*batch_size*, *time_steps*, *features*) benötigt. Hierbei sind *batch_size* und *time_steps* verstellbare Hyperparameter des neuronalen Netzwerks (Tabaro et al., 2024).

Tabelle 2: Architektur vom Q-Netzwerk

Schichte (Typ)	Einheiten	Aktivierungsfunktion
LSTM (Input)	64	-
LSTM	32	-
Dense	32	ReLU
Rense (Output)	Action_space	Linear

5 Diskussion

5.1 Methoden und Praktiken in der Literatur

Im vorliegenden Abschnitt erfolgt eine Zusammenfassung der verschiedenen KI-basierten Methoden und Praktiken, welche in Kapitel Vier von unterschiedlichen Forschern einer Analyse und Bewertung unterzogen wurden. Im vorliegenden Abschnitt erfolgt die Beantwortung der in Kapitel Eins aufgeworfenen Forschungsfrage. In Anbetracht der zeitlichen Entwicklung des algorithmischen Handels erfolgt zunächst eine Analyse der statistischen und mathematischen Methoden. Ein exemplarisches Beispiel ist die automatisierte Exit- und Wiedereinstiegsstrategie, welche die Charakteristika der automatisierten Entscheidungsfindung im algorithmischen Handel auf Basis der Marktbedingungen veranschaulicht. In der jüngeren Vergangenheit haben Forscher damit begonnen, KI-Technologien in traditionelle algorithmische Handelsstrategien zu integrieren. Das übergeordnete Ziel dieses Ansatzes besteht in einer Optimierung der Bewertung von Risiken im spezifischen Finanzmarkt durch KI-Unterstützung sowie einer Steigerung der Effizienz der Entscheidungsfindung.

In den vergangenen Jahren lässt sich eine Zunahme der Integration von KI-Technologien in algorithmische Handelssysteme beobachten, welche eine Steigerung der Rentabilität in der praktischen Anwendung zum Ziel hat. Die genannten Technologien umfassen nahezu alle aktuellen Kategorien der KI-Entwicklung, darunter sowohl algorithmenbasierte maschinelle Lernmethoden als auch datengesteuerte Methoden des DL. Die hier thematisierten ML- und DL-Methoden lassen

sich als KI-Technologien kategorisieren, die von Forschern zur Prognose zukünftiger Trends zum Einsatz kommen. Diese prädiktiven KI-Technologien entsprechen dem Verhalten privater Händler, die auf Grundlage ihrer Einschätzung zukünftiger Marktentwicklungen Finanzanlagen kaufen oder verkaufen, um Gewinne zu erzielen. Es sei jedoch hervorgehoben, dass die genannten Vorhersagemethoden nicht darauf abzielen, den exakten Preis eines bestimmten Finanzinstruments am nächsten Handelstag vorherzusagen. In der Tat lässt sich, wie von der Effizienzmarkthypothese postuliert, eine exakte Vorhersage von Preisen für Finanzinstrumente nicht treffen. Das Ziel der Prognose besteht demgemäß darin, durch unterschiedliche Methoden potenzielle zukünftige Trends abzuleiten.

Im Rahmen der Forschung zum traditionellen maschinellen Lernen werden Klassifikations- und Regressionsalgorithmen eingesetzt, um künftige Trends zu analysieren. Die Analyseergebnisse ermöglichen es Händlern, direktionalen Handel zu betreiben und daraus zu profitieren. Allerdings gelangten Henrique et al. (2023) in ihren Experimenten zu dem Ergebnis, dass maschinelle Lernmethoden, die auf Klassifikationsalgorithmen basieren, bei der Vorhersage von Marktbewegungen keinen Vorteil gegenüber zufälligen Modellen bieten. In Anbetracht der Tatsache, dass zukünftige Preise von Finanzanlagen durch Regressionsanalysen nicht prognostiziert werden können, wendete Malik (2023) RF und SVM an, um die Preisvolatilität im *Bitcoin-Futures-Markt* vorherzusagen. Dabei erzielte er bessere Ergebnisse als mit ökonometrischen Methoden. Aufgrund der hohen Anforderungen an gekennzeichneten Daten, die das überwachte Lernen mit sich bringt, bedienten sich Chakole et al. (2021) innovativer Ansätze wie des unüberwachten Lernen und setzten *K-Means* ein, um aus historischen Handelssitzungen gewinnbringende Muster zu isolieren. Unter der Prämisse der Reproduzierbarkeit historischer Muster wäre es Investoren theoretisch möglich, durch die Imitation erfolgreicher Handelsstrategien aus der Vergangenheit Gewinne zu erzielen.

Im Gegensatz zu maschinellen Lernmethoden legen DL-Methoden größeren Wert auf die Bedeutung der Daten. Die Hoffnung der Forschenden ist, dass tief geschichtete neuronale Netzwerke Informationen aus vielfältigen Finanzmarktdaten extrahieren können, die Menschen oft verborgen bleiben. Komplexe Netzwerke wie LSTM weisen im Allgemeinen eine höhere Informationsgewinnungskapazität auf als einfache Netzwerke wie MLP. Innerhalb der Finanzmärkte findet sich eine Vielzahl an Daten, wobei Zeitreihendaten eine besonders häufige Erscheinungsform darstellen. Ein Beispiel für Zeitreihendaten ist der historische Kursverlauf einer Aktie. Diese Daten reflektieren jedoch Prozesse, die durch eine Vielzahl von Einflussfaktoren determiniert werden, und enthalten folglich ein signifikantes Maß an Informationen. Um aus Zeitreihendaten, die durch zahlreiche Einflussfaktoren determiniert werden, wesentliche Informationen effizient extrahieren zu können, entwickelten Huang & Song (2023) eine Methode zur Verwendung von BiLSTM. Diese ermöglicht die Nutzung von Informationen aus beiden Richtungen der Zeitreihe. Der Vergleich von Handelsstrategien auf Basis von tiefem Verstärkungslernen mit zwei Basismodellen, dem Buy-and-Hold-Ansatz und der RRL-Methode, zeigte, dass DNN-RL, LSTM-RL und BiLSTM-RL signifikant höhere Gesamtergebnisse erzielten (Huang & Song, 2023).

Die wesentlichen Vorteile von LSTM-RL und BiLSTM-RL lassen sich wie folgt zusammenfassen: Erstens sind LSTM und BiLSTM in der Lage, Marktzustände aus rohen und verrauschten

Daten zu erkennen. Zweitens können sie dank ihrer Online-Natur schnell auf neue Marktbedingungen reagieren. Besonders BiLSTM-RL übertrifft LSTM-RL, da es sowohl vergangene als auch zukünftige Informationen erfasst und reziproke Beziehungen in den Daten berücksichtigt (Huang & Song, 2023).

Einige Forscherinnen und Forscher haben jedoch die Informationsdichte von Zeitreihendaten infrage gestellt, da die *Darstellung der Daten* eine entscheidende Rolle im DL spielt, und die extrahierbare Information eng mit der Art der Darstellung verknüpft ist (Yilmaz et al., 2024). Um den Mangel an relationalen Informationen in Zeitreihendaten zu beheben, wurde eine hybride Methode vorgeschlagen, welche die Integration von CNN zur Entwicklung von Handelsstrategien beinhaltet. Die hier beschriebene Methode kombiniert konventionelle Zeitreihendaten mit graphischen Darstellungen von Aktienbeziehungen. Dabei werden die hohen Fähigkeiten von CNN zur Informationsgewinnung aus zweidimensionalen Daten genutzt (Yilmaz et al., 2024).

Um das Problem von *Overfitting* im DL zu vermeiden und gleichzeitig kontinuierliche und schnelle Entscheidungsprozesse zu ermöglichen, fokussierten sich Forscher auf RL und DRL. Die Grundidee des RL besteht darin, dass der Agent durch fortwährende Interaktion mit der Umgebung die optimale dynamische Handelsstrategie erlernt und gleichzeitig Risiken minimiert. In der überwiegenden Mehrheit der Fälle erfolgt eine Anpassung der Umwelt des Agenten mit dem Ziel, durch Interaktion effizientere Handelsstrategien zu entwickeln. Als Beispiel sei hier die DCRL-Methode von Aloud & Alkhamees (2021) angeführt, welche eine auf Richtungsänderungen basierende Umweltrepräsentation verwendet und den Q-Learning-Algorithmus zum Training einsetzt. Diese Darstellung der Marktveränderungen ähnelt der Anwendung von Klassifikationsalgorithmen zur Marktprognose im maschinellen Lernen. Aloud & Alkhamees konnten nachweisen, dass der Q-Learning-Algorithmus die Leistung im algorithmischen Handel steigern kann. Die Einführung von Richtungsänderungen zielt darauf ab, die herkömmliche Analyse basierend auf festen Zeitintervallen durch eine dynamische Zustandsrepräsentation zu ersetzen. Um ähnliche Ziele zu erreichen, erweiterten Tabaro et al. (2024) die Umwelt des Agenten durch Sentimentanalysen, um die Informationsdichte der Preiszeitreihen zu erhöhen.

5.2 Chancen und Herausforderungen durch AI

Die Beantwortung der in Kapitel Eins aufgeworfenen zweiten Forschungsfrage erfolgt durch eine Kombination von Literaturrecherche und eigener Erfahrung des Autors als Entwickler von KI-Anwendungen. Ziel ist die Analyse und eingehende Diskussion der Chancen und Herausforderungen, die KI dem algorithmischen Handel bietet. Der vorliegende Abschnitt verfolgt das Ziel, die divergierenden Perspektiven von Forschern auf den Einfluss von KI auf den algorithmischen Handel zu integrieren. Im vorliegenden Abschnitt werden die Ansichten von Forschern mit unterschiedlichen Forschungsschwerpunkten einander gegenübergestellt, sodass die Leser die neuesten Entwicklungen und Auswirkungen der KI-Technologie im algorithmischen Handel aus einer umfassenden Perspektive erfassen können.

Die durchgeführte Literaturrecherche belegt, dass verschiedene KI-Technologien dem konventionellen algorithmischen Handel vielversprechende Möglichkeiten eröffnen. Im Rahmen dieser Untersuchung werden die mit der Anwendung von KI-Technologien verbundenen Chancen als

eine Erweiterung der konventionellen Methoden zur Entscheidungsfindung beim Kaufen und Verkaufen interpretiert. Durch den Einsatz diverser KI-Technologien ist es Händlern möglich, ihre Entscheidungen nicht nur auf traditionelle technische Indikatoren, sondern ebenfalls auf Informationen aus einer Vielzahl unterschiedlicher Datenquellen zu stützen. Unter Zuhilfenahme maschineller Lernmodelle ist es Händlern möglich, zukünftige Preisentwicklungen von Vermögenswerten auf Basis von Zeitreihendaten aus verschiedenen Finanzmärkten vorherzusagen. Ein Beispiel für den Einsatz von KI-Technologien ist die Klassifizierung von Finanzmarktdaten sowie die Durchführung von Regressionsanalysen, um potenzielle künftige Marktschwankungen abzuleiten.

Ein weiterer Vorteil, den KI dem algorithmischen Handel bietet, ist die Möglichkeit, zusätzliche Informationsquellen in die Zustandsrepräsentation eines Agenten einzubeziehen, die über reine Preisdaten hinausgehen (Tabaro et al., 2024). Algorithmische Handelssysteme, die auf DRL basieren, sind folglich in der Lage, Preisinformationen und Sentimentanalysen aus anderen Textquellen in ihre Handelsstrategien zu integrieren, was ein erhöhtes Renditepotenzial zur Folge hat. KI-gestützter algorithmischer Handel kann folglich die Entscheidungsprozesse eines realen Händlers imitieren, der in der Regel fundamentale Analysen zur Entscheidungsfindung heranzieht (Tabaro et al., 2024), anstatt ausschließlich technische Analysen durchzuführen. Dieser durch RL erzielte Vorteil kann dazu beitragen, das Vertrauen der Händler in algorithmische Handelsstrategien zu stärken.

Die Entwicklung und das Training der im algorithmischen Handel verwendeten KI-Technologien sind jedoch mit hohen Anforderungen an die Datenqualität verbunden. Die Verwendung unterschiedlicher KI-Algorithmen bedingt die Verwendung diverser Datentypen. Modelle des DL sind in der Regel datengetrieben und benötigen daher große Mengen an gekennzeichneten Daten für das Training, was die Datenbeschaffung für Forscher zu einer großen Herausforderung macht. Die Auswahl geeigneter Merkmale und Daten zur Darstellung der Umweltzustände erweist sich bei der Entwicklung von auf RL basierenden Handelssystemen ebenfalls als komplex (Aloud & Alkhamees, 2021). Da RL auf Interaktionen mit der Umgebung angewiesen ist, besteht die Möglichkeit, dass algorithmische Händler auch ohne die Verwendung großer Mengen an gekennzeichneten Daten zu besseren Handelsstrategien gelangen. Andererseits besteht die Möglichkeit, dass die Agenten im RL Handelsstrategien entwickeln, die den Erwartungen menschlicher Händler widersprechen. Dies kann dadurch begründet werden, dass die für die Strategieentwicklung relevanten Informationen oft durch emotionale und kognitive Verzerrungen übergangen werden. Dies könnte potenziell zu einer Steigerung der erwarteten Rendite führen, indem KI-gestützte Strategien auf neue Weise genutzt werden, die menschliches Denken nicht antizipiert.

Die Anwendung von KI trägt ebenfalls zu einer Vereinfachung der Arbeitsabläufe verschiedener Anlegertypen bei, indem sie optimierte Handelsstrategien bereitstellt (Sun et al., 2019). Die Anwendung von KI reduziert die Komplexität des algorithmischen Handelsprozesses und ermöglicht die Bereitstellung differenzierter Handelsstrategien. Der algorithmische Handel erweist sich insbesondere deshalb als attraktive Handelsform, da Computersysteme in der Lage sind, emotionale Einflüsse, die das Handeln menschlicher Händler maßgeblich beeinflussen, zu eliminieren. Allerdings lässt sich der zusätzliche Nutzen, den diese emotional neutralen KI-Strategien mit sich

bringen, nicht mit Sicherheit prognostizieren. Der Vorteil algorithmischer Handelssysteme mit KI-Unterstützung besteht in der Bereitstellung einer neuen, vom Menschen abweichenden Handelsweise.

In der von Henrique et al. (2023) vorgestellten Methodik wurde davon ausgegangen, dass ein Benutzer die maschinell gestützte Empfehlung zur Preisrichtungsprognose stets befolgt. Inwiefern menschliche Händler jedoch den von KI vorgeschlagenen Anlagestrategien jedoch tatsächlich vertrauen, bleibt eine bislang noch offene Forschungsfrage. Obschon maschinelle Lernmethoden im Finanzbereich weit verbreitet und erfolgreich angewendet werden, erweisen sie sich vielfach als auf spezifische Untersuchungen zugeschnitten, sodass sie in Bezug auf Erklärbarkeit, Vergleichbarkeit und Reproduzierbarkeit eingeschränkt sind (Sokolovsky & Arnaboldi, 2023). Des Weiteren besteht die Möglichkeit einer Diskrepanz zwischen den von KI unterstützten algorithmischen Handelsstrategien und denen menschlicher Investoren, was zu Vertrauensproblemen führen kann. Ein weiterer Grund hierfür ist, dass KI nicht immer in der Lage ist, die Stimmung und Einstellung der Investoren zu den Markttrends zu berücksichtigen (Liu et al., 2022).

Ein weiteres Problem von KI-gestütztem algorithmischem Handel besteht in der Tatsache, dass Entwicklung und Tests zumeist auf einem einzigen Markt stattfinden. So wurde die Sentimentanalyse von Tabaro et al. (2024) lediglich für Tesla-Aktien evaluiert. Die Generalisierungsfähigkeit solcher Handelsstrategien auf andere Märkte ist daher bislang ungeklärt. Des Weiteren sind einige algorithmische Handelsstrategien auf spezifische Vermögenswerte beschränkt, wodurch sie bei Portfoliomanagement-Entscheidungen nur begrenzt Unterstützung bieten (Aloud & Alkhamees, 2021). Die Leistungsfähigkeit eines Modells in Handelsstrategien mit DL ist in hohem Maße von der Datenqualität abhängig. Dies trifft insbesondere auf Sentimentanalysen aus Textquellen wie Finanzberichten, Nachrichtenartikeln und sozialen Medien zu (Tabaro et al., 2024).

5.3 Reflexion und Ausblick

Bei dieser Arbeit handelt es sich um eine systematische Literaturübersicht mit dem Ziel, Lesern, die an der Anwendung von KI im Finanzbereich interessiert sind, ein möglichst umfassendes Einführungshandbuch an die Hand zu geben. Die Zielgruppe umfasst sowohl Leser mit Erfahrung im Finanzmarkt als auch Forscher mit ML-Kenntnissen aus anderen akademischen Disziplinen. Durch die in Abschnitt eins aufgeworfenen Forschungsfragen und die Ergebnisse der Literaturanalyse in Abschnitt vier soll dem Leser ein klarer Überblick über die aktuellen Anwendungen und Herausforderungen von KI im algorithmischen Handel gegeben werden.

Diese Arbeit befasst sich jedoch ausschließlich mit den Perspektiven der akademischen Forschung zu KI im algorithmischen Handel und berücksichtigt nicht die reale Investmentpraxis. In der Praxis wird der Finanzmarkt nicht nur von verschiedenen unerwarteten Ereignissen beeinflusst, auf die KI möglicherweise nicht schnell genug reagieren kann, sondern auch von den Handlungen anderer Investoren. Zukünftige Forschung könnte auf dieser Arbeit aufbauen und untersuchen, wie der Markt reagieren würde, wenn alle Marktteilnehmer KI-gestützte algorithmische Handelsstrategien einsetzen würden. Dabei sollten die folgenden Fragen berücksichtigt werden:

Würde KI selbst zu einem erwarteten Einflussfaktor? Könnte der Anteil KI-gestützter Händler am Markt ein zukünftiger Indikator für die technische Analyse werden?

Die Fortschritte in der KI-Technologie sowie die Steigerung der Hardwareleistung führen zu einer zunehmenden Relevanz der KI-Anwendung im Finanzbereich, sowohl in der akademischen als auch in der industriellen Forschung. Um die Leistungsfähigkeit dieser neuen Technologien adäquat beurteilen zu können, ist die Anwendung statistischer Methoden erforderlich, um die Mängel der KI hinsichtlich Erklärbarkeit und Vergleichbarkeit zu überwinden (Sokolovsky & Arnaboldi, 2023). In künftigen Forschungsarbeiten sollte neben der Weiterentwicklung von KI-Technologien auch deren Erfolgsfaktoren untersucht werden. In einer Zeit, in der generative KI auf Basis großer Sprachmodelle zunehmend Verbreitung findet, ist es von großem Wert, dass möglichst viele Menschen die Prinzipien der KI verstehen und erkennen, wie KI die Arbeit von Menschen verbessern kann. In künftiger Forschung sollte eine Differenzierung zwischen der Anwendung von KI im Allgemeinen und dem Einsatz generativer KI auf Basis großer Sprachmodelle im algorithmischen Handel vorgenommen werden. Die Forschung auf diesem Gebiet ist derzeit begrenzt, sodass eine eingehende Untersuchung der potenziellen Anwendungen generativer KI im Finanzwesen erforderlich ist.


Obwohl viele der beschriebenen KI-Werkzeuge theoretisch in der Lage sind, menschlichen Händlern zu höheren Gewinnen zu verhelfen, können sie derzeit menschliche Händler nicht vollständig ersetzen und spielen eher eine unterstützende Rolle. Da diese Arbeit den Fokus auf den Einfluss der KI auf den algorithmischen Handel legt, wurden Optimierungsmöglichkeiten auf Basis der von KI bereitgestellten Anlagestrategien nicht betrachtet. Verschiedene Fachleute haben Vorschläge für Optimierungsmethoden gemacht. In der Literatur finden sich verschiedene Vorschläge für Optimierungsmethoden. Profitable Anlagestrategien könnten durch eine Kombination menschlicher Expertise und KI entwickelt werden, sofern das Vertrauen korrekt berechnet wird (Henrique et al., 2023). In einer alternativen Forschungsrichtung wird die Verwendung heuristischer Algorithmen zur Optimierung von KI-generierten Anlagestrategien empfohlen. So wurden beispielsweise von (Ozcalici & Bumin, 2022) genetische Algorithmen eingesetzt, um die Filterregelparameter im Aktienhandel zu optimieren und dadurch die Portfoliorendite zu steigern.

Die Verbindung von Theorie und Praxis stellt eine weitere beachtenswerte Herausforderung dar. In der gesichteten Literatur liegt der Fokus nahezu aller Forschenden auf den algorithmischen Prinzipien der verschiedenen Arten von KI-Technologien, d.h. auf mathematischen Ableitungen und Modellierungsprozessen. Obschon mathematische Modelle für die Entwicklung leistungstarker algorithmischer Handelssysteme von entscheidender Bedeutung sind, führt diese Betonung der mathematischen Modellierung zugleich dazu, dass viele dieser komplexen Forschungsergebnisse kaum praktische Orientierung bieten. Nach einer eingehenden Analyse und Diskussion dieser Forschungsergebnisse kann festgestellt werden, dass die Bemühungen, algorithmischen Handel durch die Optimierung mathematischer Modelle zu verbessern, durchaus als positiv zu bewerten sind. Dennoch darf die Herausforderung nicht übersehen werden, wie diese KI-Modelle in die Praxis des algorithmischen Handels integriert werden sollten. Diesbezüglich stellt sich weiterhin die interessante und anspruchsvolle Frage, auf welche Art und Weise bestehende

algorithmische Handelssysteme, insbesondere solche für den Hochfrequenzhandel, durch neue KI-Funktionen erweitert werden können.

Im Rahmen künftiger Forschungsarbeiten sollte zudem untersucht werden, auf welche Weise sich durch den Einsatz von KI ein bestimmter Effekt erzielen lässt. Dies impliziert, dass die kontinuierlichen Fortschritte im Bereich der KI-Technologie möglicherweise in der Lage sind, die Schwächen konventioneller algorithmischer Handelssysteme zu kompensieren. Diese Studie postuliert, dass unabhängig von der spezifischen KI-Technologie das Ziel der Forscher darin besteht, ein KI-unterstütztes algorithmisches Handelssystem zu entwerfen und zu nutzen, um profitable Investitionsstrategien zu entwickeln. Daher erscheint es sinnvoll, die Schwächen herkömmlicher algorithmischer Handelssysteme sowie die potenziellen Optimierungen durch den Einsatz von KI-Technologien zu untersuchen.

Literaturverzeichnis

- Alaminos, D., Salas, M. B., & Callejón-Gil, Á. M. (2024). Managing extreme cryptocurrency volatility in algorithmic trading: EGARCH via genetic algorithms and neural networks. *Quantitative Finance and Economics*, 8(1), 153–209. <https://doi.org/10.3934/QFE.2024007>
- Aloud, M. E., & Alkhamees, N. (2021). Intelligent Algorithmic Trading Strategy Using Reinforcement Learning and Directional Change. *IEEE Access*, 9, 114659–114671. <https://doi.org/10.1109/ACCESS.2021.3105259>
- Barucci, E., Bonollo, M., Poli, F., & Rroji, E. (2021). A machine learning algorithm for stock picking built on information based outliers. *Expert Systems with Applications*, 184. <https://doi.org/10.1016/j.eswa.2021.115497>
- Bus, oniu, L. B., Babuška, R., & De Schutter, B. (2006). *Multi-Agent Reinforcement Learning: A Survey*.
- Chakole, J. B., Kolhe, M. S., Mahapurush, G. D., Yadav, A., & Kurhekar, M. P. (2021). A Q-learning agent for automated trading in equity stock markets. *Expert Systems with Applications*, 163. <https://doi.org/10.1016/j.eswa.2020.113761>
- Chang, Y. K., & Chou, R. K. (2022). Algorithmic trading and market quality: Evidence from the Taiwan index futures market. *Journal of Futures Markets*, 42(10), 1837–1855. <https://doi.org/10.1002/fut.22362>
- Goldstein, M. A., Kumar, P., & Graves, F. C. (2014). Computerized and high-frequency trading. *Financial Review*, 49(2), 177–202. <https://doi.org/10.1111/fire.12031>
- Gurung, N., Hasan, R., Md, , Gazi, S., & Zahidul Islam, M. (2024). *Journal of Business and Management Studies Algorithmic Trading Strategies: Leveraging Machine Learning Models for Enhanced Performance in the US Stock Market*. <https://doi.org/10.32996/jbms>
- Henrique, B. M., Sobreiro, V. A., & Kimura, H. (2023). Practical machine learning: Forecasting daily financial markets directions. *Expert Systems with Applications*, 233. <https://doi.org/10.1016/j.eswa.2023.120840>
- Huang, Y., & Song, Y. (2023). A new hybrid method of recurrent reinforcement learning and BiLSTM for algorithmic trading. *Journal of Intelligent and Fuzzy Systems*, 45(2), 1939–1951. <https://doi.org/10.3233/JIFS-223101>
- Huang, Y., Wan, X., Zhang, L., & Lu, X. (2024). A novel deep reinforcement learning framework with BiLSTM-Attention networks for algorithmic trading. *Expert Systems with Applications*, 240. <https://doi.org/10.1016/j.eswa.2023.122581>
- Huang, Y., Zhou, C., Cui, K., & Lu, X. (2024a). A multi-agent reinforcement learning framework for optimizing financial trading strategies based on TimesNet. *Expert Systems with Applications*, 237, 121502. <https://doi.org/10.1016/j.eswa.2023.121502>

- Huang, Y., Zhou, C., Cui, K., & Lu, X. (2024b). Improving algorithmic trading consistency via human alignment and imitation learning. *Expert Systems with Applications*, 253. <https://doi.org/10.1016/j.eswa.2024.124350>
- Jain, A., Jain, C., & Jiang, C. X. (2021). Active Trading in ETFs: The Role of High-Frequency Algorithmic Trading. *Financial Analysts Journal*, 77(2), 66–82. <https://doi.org/10.1080/0015198X.2020.1865694>
- Janardhanan, P., & Sabika, F. (2015). *Effectiveness of Support Vector Machines in Medical Data mining*.
- Janiesch, C., Zschiech, P., & Heinrich, K. (2021). Machine learning and deep learning. *Electronic Markets*, 31(3), 685–695. <https://doi.org/10.1007/s12525-021-00475-2>
- Koegelenberg, D. J. C., & van Vuuren, J. H. (2024). A dynamic price jump exit and re-entry strategy for intraday trading algorithms based on market volatility. *Expert Systems with Applications*, 243, 122892. <https://doi.org/10.1016/j.eswa.2023.122892>
- Lecun, Y., Bengio, Y., & Hinton, G. (2015). Deep learning. In *Nature* (Bd. 521, Nummer 7553, S. 436–444). Nature Publishing Group. <https://doi.org/10.1038/nature14539>
- Liu, C., Yan, J., Guo, F., & Guo, M. (2022). Forecasting the Market with Machine Learning Algorithms: An Application of NMC-BERT-LSTM-DQN-X Algorithm in Quantitative Trading. *ACM Transactions on Knowledge Discovery from Data*, 16(4), 1–22. <https://doi.org/10.1145/3488378>
- Liu, H.-H., Shu, H.-J., & Chiu, W.-N. (2023). Noxtrader: Lstm-Based Stock Return Momentum Prediction For Quantitative Trading. In *Advances in Artificial Intelligence and Machine Learning; Research* (Bd. 3, Nummer 4). <https://www.oajaiml.com/>
- Malik, A. (2023). A comparison of machine learning and econometric models for pricing perpetual Bitcoin futures and their application to algorithmic trading. *Expert Systems*, 40(10). <https://doi.org/10.1111/exsy.13414>
- Ozcalici, M., & Bumin, M. (2022). Optimizing filter rule parameters with genetic algorithm and stock selection with artificial neural networks for an improved trading: The case of Borsa Istanbul. *Expert Systems with Applications*, 208. <https://doi.org/10.1016/j.eswa.2022.118120>
- Russell, S. J., Norvig, P., Davis, E., Edwards, D. D., Forsyth, D., Hay, N. J., Malik, J. M., Mittal, V., Sahami, M., Thrun, S., Columbus, B., New, I., San, Y., Upper, F., River, S., Cape, A., Dubai, T., Madrid, L., Munich, M., ... Tokyo, T. (2003). *Artificial Intelligence A Modern Approach Third Edition*.
- Sahu, S. K., Mokhade, A., & Bokde, N. D. (2023). An Overview of Machine Learning, Deep Learning, and Reinforcement Learning-Based Techniques in Quantitative Finance: Recent Progress and Challenges. In *Applied Sciences (Switzerland)* (Bd. 13, Nummer 3). MDPI. <https://doi.org/10.3390/app13031956>

- Sevastjanov, P., Kaczmarek, K., & Rutkowski, L. (2024). A multi-model approach to the development of algorithmic trading systems for the Forex market. *Expert Systems with Applications*, 236. <https://doi.org/10.1016/j.eswa.2023.121310>
- Shavandi, A., & Khedmati, M. (2022). A multi-agent deep reinforcement learning framework for algorithmic trading in financial markets. *Expert Systems with Applications*, 208. <https://doi.org/10.1016/j.eswa.2022.118124>
- Sokolovsky, A., & Arnaboldi, L. (2023). A generic methodology for the statistically uniform & comparable evaluation of Automated Trading Platform components. *Expert Systems with Applications*, 223. <https://doi.org/10.1016/j.eswa.2023.119836>
- Sun, E. W., Kruse, T., & Chen, Y. T. (2019). Stylized algorithmic trading: satisfying the predictive near-term demand of liquidity. *Annals of Operations Research*, 281(1–2), 315–347. <https://doi.org/10.1007/s10479-019-03150-0>
- Tabaro, L., Kinani, J. M. V., Rosales-Silva, A. J., Salgado-Ramírez, J. C., Mújica-Vargas, D., Escamilla-Ambrosio, P. J., & Ramos-Díaz, E. (2024). Algorithmic Trading Using Double Deep Q-Networks and Sentiment Analysis. *Information (Switzerland)*, 15(8). <https://doi.org/10.3390/info15080473>
- Takara, L. D. A., Santos, A. A. P., Mariani, V. C., & Coelho, L. D. S. (2024). Deep reinforcement learning applied to a sparse-reward trading environment with intraday data. *Expert Systems with Applications*, 238. <https://doi.org/10.1016/j.eswa.2023.121897>
- Vo, A., & Yost-Bremm, C. (2020). A High-Frequency Algorithmic Trading Strategy for Cryptocurrency. *Journal of Computer Information Systems*, 60(6), 555–568. <https://doi.org/10.1080/08874417.2018.1552090>
- Vom Brocke, J., Simons, A., Niehaves, B., Niehaves, B., Riemer, K., Brocke, J., Vom, ;, Simons, A. ;, Niehaves, B. ;, Niehaves, B. ;, Riemer, K. ;, Plattfaut, R. ;, & Cleven, A. (2009). *Reconstructing the giant: On the importance of rigour in documenting the literature search process*. <https://aisel.aisnet.org/ecis2009/161>
- Wilhelmina Afua Addy, Adeola Olusola Ajayi-Nifise, Binaebi Gloria Bello, Sunday Tubokirifuruar Tula, Olubusola Odeyemi, & Titilola Falaiye. (2024). Algorithmic Trading and AI: A Review of Strategies and Market Impact. *World Journal of Advanced Engineering Technology and Sciences*, 11(1), 258–267. <https://doi.org/10.30574/wjaets.2024.11.1.0054>
- Yilmaz, M., Keskin, M. M., & Ozbayoglu, A. M. (2024). Algorithmic stock trading based on ensemble deep neural networks trained with time graph. *Applied Soft Computing*, 163. <https://doi.org/10.1016/j.asoc.2024.111847>

Anhang A: Titel des Anhangs

Anhang B: Titel des Anhangs

Eidesstattliche Erklärung

Hiermit versichere ich, die vorliegende Arbeit mit dem Titel

„The Impact of AI Technology on Algorithmic Trading“

selbständig, ohne fremde Hilfe und ohne Benutzung anderer als der von mir angegebenen Quellen angefertigt zu haben. Alle aus fremden Quellen direkt oder indirekt übernommenen Gedanken sind als solche gekennzeichnet.

Die Arbeit wurde noch keiner Prüfungsbehörde in gleicher oder ähnlicher Form vorgelegt und wurde noch nicht veröffentlicht.

Ich erkläre mich damit einverstanden, dass die Arbeit mithilfe eines Softwaredienstes auf Plagiate untersucht wird.

Dresden, den 01.11.2024

Wanjin Li

Vorname Nachname

Wanjin Li

Unterschrift